

# 目 录

第 1 章 绪论	- 1 -
1.1 研究背景和意义	- 1 -
1.2 国内外对疲劳驾驶检测的研究现状	- 2 -
1.2.1 疲劳检测方法概述	- 2 -
1.2.2 国外研究现状	- 4 -
1.2.3 国内研究现状	- 5 -
1.3 主要研究内容和组织结构	- 6 -
1.3.1 主要研究内容	- 6 -
1.3.2 组织结构	- 7 -
第 2 章 基于 AdaBoost 算法的人脸检测	- 9 -
2.1 人脸检测方法概述	- 9 -
2.2 矩形特征及积分图	- 11 -
2.2.1 Haar-Like 特征	- 12 -
2.2.2 积分图	- 13 -
2.3 AdaBoost 算法	- 16 -
2.3.1 AdaBoost 算法简介	- 16 -
2.3.2 AdaBoost 算法原理描述	- 17 -
2.3.3 AdaBoost 算法性能分析	- 19 -
2.3.4 级联分类器原理	- 21 -
2.3.5 级联分类器构造算法	- 22 -
2.3.6 级联分类器检测流程	- 24 -
2.4 人脸检测实验结果	- 25 -
2.5 本章小结	- 26 -
第 3 章 基于改进的 AdaBoost 算法的人眼检测	- 27 -
3.1 AdaBoost 算法的退化现象	- 27 -
3.2 AdaBoost 算法的改进	- 27 -
3.3 构造人脸-人眼分类器进行人眼检测	- 30 -

3.3.1 人眼粗定位.....	30 -
3.3.2 构造人脸-人眼分类器.....	31 -
3.4 人眼检测实验结果及分析 .....	31 -
3.4.1 OpenCV 简介 .....	31 -
3.4.2 训练样本集和预处理.....	32 -
3.4.3 训练分类器.....	35 -
3.4.4 实验结果和分析.....	35 -
3.5 本章小结 .....	39 -
<b>第4章 人眼状态识别及疲劳状态检测.....</b>	<b>40</b>
4.1 人眼状态识别方法概述 .....	40
4.2 基于投影法的人眼状态识别 .....	42 -
4.2.1 图像的二值化.....	42 -
4.2.2 数学形态学处理.....	44 -
4.2.3 人眼状态的判断.....	46 -
4.3 基于 PERCLOS 方法的疲劳状态检测.....	47 -
4.3.1 PERCLOS 方法检测原理 .....	47 -
4.3.2 基于动态 PERCLOS 辅助眨眼频率的疲劳状态判断.....	50 -
4.4 实验结果及分析 .....	51
4.4.1 实验平台.....	51
4.4.2 实验结果.....	52 -
4.5 本章小结 .....	54 -
<b>结 论.....</b>	<b>56 -</b>
<b>参考文献.....</b>	<b>58 -</b>
<b>攻读硕士学位期间发表的论文和取得的科研成果.....</b>	<b>61</b>
<b>致 谢.....</b>	<b>63 -</b>

# 第 1 章 绪论

## 1.1 研究背景和意义

随着社会经济的持续高速发展，凭借其能提高日常效率、提升生活质量以及拓展活动空间等特征，汽车已经成为我们日常生活中最重要的交通工具。我国长期以来都是汽车消费大国，据统计显示 2013 年我国汽车销量约在 2500 万台左右。汽车行业的蒸蒸日上是我国科技进步、经济繁荣的一个缩影，但是随着汽车的普及，随之而来的诸多问题也日益显现，其中，道路安全问题一直占据核心地位。就全球范围来看，道路交通事故甚至已经发展成为人类非正常死亡的首要因素。由于道路交通事故的频发，各个国家每年都要承担巨额的经济损失以及付出惨痛的生命代价。据中国统计年鉴（2013）数据显示，截止至 2012 年末，我国全年汽车交通事故发生数约为 14 万起，占交通事故发生总数的 70% 以上，汽车交通事故死亡人数约为 4.4 万人，占交通事故死亡总人数的 75% 左右<sup>[1]</sup>。疲劳驾驶是我国发生汽车交通事故的主要原因之一。交通部门统计的数据显示，交通事故中和疲劳驾驶相关的超过 60%，而造成疲劳驾驶的交通事故约占总数的 20%，造成多起严重的交通事故的占为 40%，疲劳驾驶的危害性是显而易见的。

疲劳驾驶主要是指在行车途中由于驾驶员休息不足、驾驶时间过长或者其它心理方面的压力造成的体力或脑力的过度使用，从而导致驾驶员的反应能力和警戒程度大大降低的现象。它主要表现在驾驶员精神困倦、打瞌睡、驾驶操作失误甚至驾驶能力的完全丧失，最终发生了交通事故。目前，作为导致交通事故的重要原因之一的疲劳驾驶问题受到人们越来越多的关注。据相关研究表明，如果能够在行驶过程中对驾驶员的状态进行实时监测，当一开始出现疲劳驾驶状态时就给以警示，那么至少可以避免 80% 的由于疲劳驾驶导致的交通事故。所以，通过对驾驶员的疲劳检测和预警不仅可以有效降低交通事故的发生率，减少人员伤亡及财产损失，而且有利于交通部门的监管，有重大的社会意义。鉴于此，探究能否及时、有效地识别并判断驾驶者是否处在疲劳状态并且发出警告的技术对于保障安全驾驶以及安全行车具有不可替代的现实意义。

## 1.2 国内外对疲劳驾驶检测的研究现状

### 1.2.1 疲劳检测方法概述

目前国内外关于疲劳检测的方法研究主要基于以下四个维度:车辆运行参数、驾驶员生理指标、计算机视觉以及信息融合技术。

#### (1)基于车辆运行参数的检测方法

该检测方法主要检测车辆方向盘的转动情况、车道的偏离情况以及车辆的行驶速度等参数。Chang 等人利用机器视觉技术,在行车过程中对车道标志线进行实时检测,当车辆发生异常偏离并被系统检测到时,系统便会自动发出严厉的警报<sup>[2]</sup>。Volvo 汽车公司研制了一种“驾驶员警示系统”,对车辆行驶的速度进行实时检测,从而对该车辆是否处在有效控制的状态进行判断,以此来间接地判断驾驶员是否处于疲劳驾驶<sup>[3]</sup>。

基于车辆运行参数的检测方法虽然是一种非接触的方式,参数较容易提取且比较准确客观,但是它最大的缺点是会受到驾驶员的驾驶习惯、车辆的类型及驾驶条件等的影响,而且目前尚未解决特征参数疲劳程度的相关性具体量化问题。

#### (2)基于驾驶员生理参数的检测方法

该检测方法主要检测行车过程中驾驶员的各项生理指标,例如脑电图(EEG)信号、心电图(ECG)信号、肌电图(EMG)信号、脉搏跳动及呼吸频率等<sup>[4]</sup>。其中,长期以来,脑电图(EEG)信号指标一直被奉为检测是否疲劳驾驶的“金标准”。澳大利亚悉尼大学健康研究中心搜集了一些驾驶员的 EEG 信号指标,构建人工神经网络对其进行处理,通过提取不同波段不同 EEG 的典型特征并进行分类,对驾驶员的疲劳状况进行了识别<sup>[5]</sup>。焦昆等人对心率变异性与血压变异性的功率谱进行研究,并对驾驶员的精神疲劳程度进行了综合评价<sup>[6]</sup>。

由于生理参数能很快的反映出一个人的体力和精神状态,所以基于生理参数的检测方法有较好的实时性和准确性。但是该检测方法大多数采用的是接触式器材对人体进行检测,也就是提取生理参数需要使用专业仪器在驾驶员身体表面进行参数的提取,这样势必会对驾驶员造成一定的干扰,影响驾驶员正常行驶。而且检测成本比较高,较难推广。因此该方法实际应用于疲劳检测时具有一定的局限性。

#### (3)基于计算机视觉的检测方法

该检测方法主要通过摄像头实时监测,采集驾驶员面部图像,对其应用图像

处理和模式识别技术进行分析,根据参数结果来判断驾驶员是否疲劳驾驶。CMU (卡内基梅隆大学) 经过论证和反复的试验,提出了度量疲劳的物理量—单位时间内眼睛闭合时间所占的比例 PERCLOS (Percentage of Eyelid Closure over the Pupil over Time), 并提出单位时间内眼睛闭合时间占比在 80% 以上即 PERCLOS 的 P80 标准可以很好的评价驾驶员的疲劳程度。Weng 等人利用 DSP 嵌入式系统和红外光源搜集了不同驾驶员的脸部图像,采用模板匹配算法来识别驾驶员的闭眼状态和睁眼状态,把改进后的 PERCLOS 算法作为标准来评价驾驶员是否疲劳驾驶<sup>[7]</sup>。

基于计算机视觉的检测方法也是非接触式的,它具有准确性和可靠性高的优点。使用计算机视觉的方法对驾驶员的面部特征进行检测是目前解决疲劳检测的最佳技术选择。目前最常见的驾驶员眼睛状态检测就是基于计算机视觉的检测方法,应用广泛。

#### (4) 基于信息融合技术的检测方法

该方法是通过建立信息融合模型综合背景信息和多种传感器检测信息来对驾驶员的疲劳状态进行检测,以求得更高的检测精确度和准确率。从汽车的主动安全出发,采用数字图像信号处理和传感器等技术,并结合驾驶员的各种疲劳特征信息,对驾驶员的疲劳状态进行判别和预警,这样采用单一特征信息检测所造成的误警或者漏警的现象大大降低。经过大量的研究和试验结果表明,使用多特征融合的检测方法是检测驾驶员疲劳状态的一种非常有效并极具前景的检测方法。其中,华南理工大学提出基于多元信息融合技术对驾驶员疲劳程度进行检测<sup>[8]</sup>,这项技术利用摄像头和传感器等装置来检测眼睛的特征、视线方向和驾驶行为状态,通过信息融合建立疲劳特征的判决构架,最后对驾驶员的疲劳状态进行判断。

基于信息融合技术的检测方法能使疲劳检测技术得到进一步的发展和提升,并且驾驶员的疲劳状态能够客观、实时、快速准确地得到检测和判断,但是信息融合检测方法对于建立信息融合模型和各种信息的获取相对比较困难,所以其实用性有待进一步探索,但同时该方法有着良好的开发前景。

常用的疲劳驾驶检测方法各有优缺点,其对比如表 1.1 所示。

表 1.1 各种检测方法性能对比

Table 1.1 performance comparison of various detection methods

检测方法	准确性	可靠性	接触性	成本
驾驶员生理参数检测	高	低	接触式	高
车辆运行参数检测	较高	较高	非接触式	低
计算机视觉检测	较高	较高	非接触式	低
信息融合技术检测	高	高	非接触式	较低

### 1.2.2 国外研究现状

疲劳驾驶现象在很早之前就引起了人们的注意，但是直到20世纪初期才开始有实质性的研究工作，并且由于科技水平有限并没有取得突破性的成果。直到20世纪90年代，随着科技的发展驾驶疲劳检测方法和理论有了很大的完善，驾驶疲劳研究在全世界范围内都进入了活跃时期。21世纪以来，疲劳检测技术由于计算机软硬件水平的提升和计算机视觉的快速发展也陆续涌现出了新的方法和成果。国外对疲劳检测取得的一些研究成果如下：

(1)美国明尼苏达大学的Nikolaos P. Panpani Kolospoulos教授<sup>[9]</sup>开发出了一套驾驶员疲劳检测系统，它是通过安装在车内的红外线摄像头实时监测驾驶员的脸部特征，将拍摄到的图像经过处理后定位出人眼，并通过对人眼的状态进行分析来判断驾驶员的疲劳状态。

(2)美国的Electronic Safety Products公司研发制造了“转向操作注意监视器”S.A.M(steering attention monitor)<sup>[10]</sup>作为一种测量是否由于驾驶员疲劳反应变慢使得方向盘的转动减缓的传感器装置。它实质上通过一条磁性带来测量方向盘的运动情况，如果方向盘4秒钟不运动，就判断驾驶员已经疲劳，监视器就会发出报警并且一直持续到方向盘正常运动为止。

(3) 英国Southborough 大学睡眠研究中心的研究人员开发了一种名为“疲劳驾驶员警报系统(ASTiD)”的新型电子设备。它可以在驾驶员发生疲劳驾驶时给予预

警以避免疲劳驾驶的驾驶员在行驶中睡觉，从而来消除重大交通隐患。

(4) 日本尼桑公司研制出了一种电子报警系统，自动防止驾驶员打瞌睡的电子报警系统。它利用摄像设备拍摄驾驶员的眼部图像并进行处理，设置自动提醒保证驾驶员不打瞌睡<sup>[11]</sup>。当系统判断驾驶员疲劳时，就会在驾驶室中释放一种含有薄荷气味的冷空气用来帮助驾驶员保持清醒；如果效果不佳，该系统会使用声音报警；若依旧无法清醒则自动停车。

(5) 德国人发明了一种能够警示驾驶员的眼镜，它有一个与驾驶室里的电灯和声音发生器连接的灵敏的光电开关，如果驾驶员在驾驶过程中由于过度疲劳打瞌睡，则自动打开驾驶员眼镜里的光电开关，将其眼前的灯光点亮，从而引起驾驶员的警觉；如果未能见效，声音发生器会发出巨大的声音；若驾驶员仍然处于未清醒状态，光电开关会通过自动接通制动器使车辆强制停车。

(6) 美国研制的打瞌睡驾驶员侦探系统DDDS(The Drowsy Driver Detection system)<sup>[12]</sup> 测量驾驶员眨眼的持续时间、眼睑的运动以及眨眼频率等参数以判断驾驶员的疲劳状态。它的特点是不仅采用非接触式来判断驾驶员的疲劳状态，而且由于采用低能耗的多普达雷达信号系统，故而体积较小，能够方便固定在驾驶员的头部上方。

(7) 美国福特公司旗下的volvo(沃尔沃)高级汽车(2010年被中国吉利公司收购)开发出了记录驾驶员行为的预警系统。通过对驾驶员的眼睛闭合的时间、眨眼频率和头部位置转动及速度进行测量，继而检测驾驶员的疲劳信息。

(8) 日本The University of Tokyo发明了一种疲劳测试器，驾驶员可以将其戴在手腕上，其首先由内部的小型氧气电池供电，检测驾驶员行车过程中汗液中的酒精、氨以及乳酸的含量，第二步是经由外部的一个小型无线电发射装备把实时监测到的数据上传至观测中心，最后运用电脑对数据进行分析，判断司机的疲劳程度，如果驾驶员处于疲劳驾驶状态，则严厉警告驾驶员，尽量减少意外交通事故的发生<sup>[13]</sup>。

### 1.2.3 国内研究现状

由于科技实力有限，我国对计算机视觉领域和驾驶疲劳检测领域的研究相对国外来说起步较晚，与发达国家存在着一定的差距。但是随着我国科技以及经济的飞速发展，我国的科研人员也开始投入到驾驶疲劳检测领域中去。我国对疲劳

检测的一些研究成果主要有以下几个方面：

(1) 深圳市长途汽车公司的周鹏综合电子工程学理论、神经学理论以及生理学理论，分析了疲劳驾驶导致事故的内在原因，并在此基础上首创研发了“佩带式疲劳事故预防器”，以消除驾驶员行车过程中的大脑麻痹和异常疲劳，进而消除事故隐患<sup>[14]</sup>。

(2) 上海交通大学的石坚、吴远鹏、卓斌等通过传感器测量驾驶时方向盘、踏板等运动参数，判断驾驶员驾驶的安全性，发现方向盘操纵情况在一定程度上反映了驾驶员的疲劳程度<sup>[15]</sup>。如果方向盘较长时间处于静止状态，那么就说明驾驶员在打瞌睡。

(3) 中国农业大学的郑培等研制了驾驶员驾驶疲劳评测软件系统，该系统通过摄像设备和图像卡来采集驾驶员在行车过程中的面板图像，由于其具有非触性以及实时性的优势，能够方便驾驶员在正常行车中使用<sup>[16]</sup>。

(4) 吉林大学的王荣本发现可以通过获取驾驶员的嘴部以及眼睛的图像并进行分析，来判断其疲劳状态，另外还可附加对安全车距的判断，获得了一定的研究成果<sup>[17]</sup>。

(5) 重庆大学的导航与制导实验室自主研制了“高速公路智能型汽车行驶主动安全预警系统”。它是采用特征提取、模式识别和信息融合等多种技术研究开发出来的，并且已经通过国家重型汽车质量监督检测中心的测试，得到了相应的鉴定，已进入了实用化的阶段。

(6) 深圳亿龙科技有限公司研制开发的手表式 TWS 汽车驾驶疲劳预警系统，这种预警系统通过监测人体的生物信息如红外光谱、心路脉搏、生物电等对人的精神状态进行判断，当使用者被检测到出现疲劳状态时该系统会发出警告<sup>[18]</sup>。

## 1.3 主要研究内容和组织结构

### 1.3.1 主要研究内容

本文主要通过研究基于 AdaBoost 算法的人脸检测及人眼检测的过程，然后对得到的驾驶员眼睛状态进行识别，最后来检测驾驶员是否疲劳驾驶。主要研究内容如下：

(1) 人脸检测。使用统计学习的 AdaBoost 算法对视频图像进行人脸检测。研



究了利用 Haar-Like 特征和积分图的快速 AdaBoost 算法。

(2)人眼检测。人眼的检测是在人脸检测完成的基础上进行的。针对传统 AdaBoost 方法的退化现象以及困难样本中正负样本没有加以区分情况对算法的进行了改进。在算法中引入样本状态识别标记并利用新的样本权重更新方法来训练分类器,在保证原有 AdaBoost 算法关注困难样本的基础上增加被错误分类为负样本的正样本的权重,使算法更加关注于困难样本中的正样本,提高了正样本的检测率,又通过使用弱分类器的动态加权参数,进一步加快算法的收敛,达到改进 AdaBoost 算法的目的。

(3)人眼状态识别。本文采用了基于投影法的人眼状态检测算法。先对检测到的人眼区域图像通过 Ostu 最大类间方差法进行二值化处理,随后进行数学形态学处理,然后通过积分投影法对人眼信息进行提取,求得眼睛的宽高比,最后根据该比值来判断眼睛的睁闭状态。

(4)疲劳状态检测。采用了一种基于动态的 PERCLOS 辅助眨眼频率的疲劳状态检测方法。采用随时间变化的动态 PERCLOS 值,在易疲劳时间段使用 PERCLOS-P70 标准,在一般时间段使用 PERCLOS-P80 标准同时辅助眨眼频率来判断疲劳状态以达到提高疲劳检测系统的稳定性的目的。

### 1.3.2 组织结构

本文的组织结构安排如下:

第 1 章绪论,首先简要概述了课题的背景和意义,其次是疲劳检测方法的概述及国内外研究现状,最后对本文的主要研究内容和组织结构进行叙述。

第 2 章基于 AdaBoost 算法的人脸检测。首先对常用的人脸检测方法做简单介绍,提出用统计学方法中的 AdaBoost 算法作为本文进行人脸和人眼检测的检测算法,其次详细介绍了矩形特征和积分图,然后对 AdaBoost 算法的基本原理、性能进行了理论分析,在此基础上进一步介绍了算法中运用的级联分类器结构,分析了级联分类器的构造算法和检测流程。最后,基于传统 AdaBoost 算法进行了人脸检测实验,验证了该算法有较高的检测率。

第 3 章基于改进的 AdaBoost 算法的人眼检测。首先提出 AdaBoost 算法出现的退化现象,针对发现的问题进行算法的改进,阐述了改进后的算法的具体步骤。然后详细介绍基于 AdaBoost 算法的人眼检测的具体流程,从训练样本到训练分类

器，最后给出人眼检测的实验结果。

第4章人眼状态识别及疲劳状态检测。本章首先介绍了人眼状态识别的主要方法，经过分析，选择了基于投影法的人眼状态检测算法，并先对检测出的人眼图像进行二值化处理和数学形态学处理，然后再进行人眼状态的判断。其次，详细介绍了 PERCLOS 方法检测原理，并在基于 PERCLOS 方法的疲劳状态检测基础上加以改进，提出了基于动态 PERCLOS 并辅助眨眼频率的疲劳判定方法，并给出了疲劳判定流程图。最后，对模拟环境下的视频图像进行实验，取得了较好的检测结果，给出了部分实验结果和检测系统效果图。

## 第 2 章 基于 AdaBoost 算法的人脸检测

本文的最终目的是对驾驶员的疲劳状态进行检测，采用的主要检测方法是 PERCLOS 方法，而该方法最关键的问题是能否准确判断驾驶员眼睛的睁闭状态。但判断眼睛状态的前提是要能够准确地图像中找到驾驶员眼睛的位置。所以在疲劳状态检测中，对于基于 PERCLOS 检测方法而言，最主要的步骤是人眼检测和人眼状态识别。其中人眼检测是首先要解决的关键问题。

对于人眼检测，检测方式大致有两种思路。一种是在图像中利用某种方法直接进行人眼的检测；另一种则是先在图像中找到人脸区域，然后在人脸区域的基础上再进行人眼的检测。由于人眼的特征信息量并不丰富，而且眼睛在睁开和闭合两种状态下的特征差别很大。比较之下人脸比人眼拥有更多的信息量且特征也较稳定，所以在检测难易程度和准确率上前者都要优于后者。而且先检测出人脸区域为接下来的人眼检测缩小了范围，同时也避免了图像中背景区域的干扰。因此本文采用先从图像中查找人脸，然后在人脸区域上查找人眼的方法。由于人脸检测和人眼检测的实现原理在大方向上基本一致，故本文在检测方法概述层面以人脸检测为例进行阐述。

### 2.1 人脸检测方法概述

人脸检测方法是指在给定的人脸图像中，检测人脸是否存在。若存在人脸，就将所有的人脸从背景中分割出来，并且给出人脸的位置和大小等具体信息<sup>[19,20]</sup>。人脸检测就是对含有人脸的图像即静态图片或者视频图像进行检测，从图像中得到一些如人脸数目、位置或尺度等与人脸相关的数据信息。针对人脸检测过程，主要的技术难题有以下几点：

(1)头部的姿势：头部姿势的变动会影响摄像机拍摄到的人脸图像，头部转动角度过大就会导致眼睛、耳朵、嘴巴等部位都没有在图像上出现，从而影响检测效果。

(2)脸部的表情：脸部的表情会对人脸图像产生影响。

(3)脸部的器官：如眉毛、胡须、睫毛以及眼睛的有无，包括它们的形状、色

彩以及大小也都会对人脸检测有一定的影响。

(4)脸部的遮挡：如果有其他物体遮挡到人脸区域，会影响人脸的检测。

(5)成像条件：图像的光线强度、像素值、对比度乃至相机的特性都会对人脸图像产生影响，从而给人脸检测带来影响。

目前应用较为广泛的人脸检测方法共有四种：基于先验知识和规则的方法、基于模板匹配的方法、基于特征不变的方法、基于统计学习的方法。

(1) 基于先验知识和规则的方法。

该方法的规则是来自于调研者有关人脸的先验知识并且将典型人脸形成一种规则库来对人脸进行编码。该方法进行人脸定位的依据大多是利用面部特征之间的关系。因为出现在图像中的人脸，一般情况下都会有一对对称的眼睛、一个鼻子和一个嘴巴。这样，基于规则的方法就能够提出简单的规则用来描述人脸的特征。它一般还会用几何关系来描述特征之间的关系，如位置和相对距离等等。

基于先验知识和规则的方法所存在的最大问题就是很难将现有的人类知识用明确定义的规则表示出来。如果规则过于详细、精准、严格，则可能出现不能通过所有的规则，从而导致检测失败的情况。如果规则过于概括、粗略、通用，则可能会出现较高的错误检测率的情况。

(2) 基于模板匹配的方法。

该方法可以分成两种，一种是预定模板，一种是变形模板。预定模板，即先制定出标准模板，再分别计算待检测模板以及目标模板的相关参数值，然后判断相关的参数值，查看其是否符合预先制定的准则。若符合规则，则该检测区域是人脸；若不符合规则，就不是人脸。变形模板，则需预先制定出模板的参数，再进行参数值的修改，在修改时按照检测区域的数据，进行对比修改，直至收敛为止，此时方能达到检测人脸的目标。

基于模板匹配的方法主要问题是计算量较大，因为模板本身相对固定，所以对于图像中人脸的位置和旋转等姿态特征以及背景图像、光照等条件比较敏感，该方法稳健性不强。

(3) 基于特征不变的方法。

该方法与基于先验知识和规则的方法正相反，它在进行人脸检测是通过查找人脸上的不变特征来实现的。该方法主要是在外界条件改变的情况下，如姿态、

视角或光照条件等因素在改变时查找存在的固定不变的结构特征，然后再利用这些固定不变的特征去定位人脸。这种基于固定结构特征不变的方法不仅可以利用面部特征进行检测，而且还可以利用面部的集合关系来进行人脸的检测。

#### (4) 基于统计学习的方法。

基于统计学习是通过使用统计分析和机器学习的方法从样本中学习到人脸的特征或者类别。而学习中得到的人脸特征或者类别被包含在分布规律、判别规律以及模型中用于人脸检测。用基于统计学习的方法来进行人脸检测的流程为：首先，使用大量人脸和非人脸样本图片进行训练，然后由训练得到一组模型参数来构建分类器，最后通过训练好的分类器来进行人脸检测。基于统计学习的方法的人脸检测方法有：神经网络(Neural Networks, NN)方法、支持向量机(Support Vector Machine, SVM)方法、主成分分析(Principal Component Analysis, PCA)方法、子空间方法、Boosting 方法以及隐马尔可夫模型(Hidden Markov Model, HMM)方法等。P.Viola 等人最早提出使用 Boosting 方法进行人脸检测<sup>[21]</sup>，他们提出了一种称为“积分图像”的新的图像表示方法，然后采用 AdaBoost 方法对特征进行选择分类，并且选择少却重要的特征组合形成强分类器。该方法准确率高，而缺点是需要提前训练大量的标准化人脸和非人脸样本，且检测结果的优劣则取决于样本的质量好坏，同时获取标准化样本的工作量非常巨大。

通过对比分析可知，基于模板匹配的方法通常需要使用大量的先验知识，这就导致检测算法的通用性不高，同时它对图像中人脸的位置和旋转等姿态特征以及背景图像、光照等条件比较敏感，检测的鲁棒性不强。基于先验知识和规则的方法虽然简单易行，但是却大量使用先验知识放在检测中，所以导致通用性比基于模板匹配的方法更低。而且该方法还容易受光照和噪声的影响，对面部肤色较深个体的检测效果很差。基于统计学习的方法不依赖于特定的先验知识，它训练分类器是通过大量的统计学习来完成的。该方法鲁棒性好而且准确率高。因此本文选用基于统计学习方法中的 AdaBoost 算法来对驾驶员进行人脸检测和人眼检测。该算法使用 Haar-Like 特征作为分类特征，然后将训练得到的弱分类器级联得到最终的强分类器。

## 2.2 矩形特征及积分图

基于 AdaBoost 算法的人脸或人眼检测都需要提取人脸图像上的某些特征，并

根据该特征在人脸图像上的值来检测是否包含人脸或人眼。由于基于像素的图像表示和基于边缘的图像表示对于目标识别而言都存在着一定的缺陷，所以需要找到一个能更好的表示图像的方法。例如：人脸识别，如果用像素值来表示分类特征，那么不同肤色以及不同强弱光线都会造成人脸部像素值出现较大范围的变化；如果用边缘信息作为分类特征进行分类，就会使得分类缺乏一致性，并且还将增加干扰信息<sup>[22]</sup>。因此，我们对比选用一种能够更好表现图像的特征—Haar 特征。Viola 和 Jones 于 2001 年提出了积分图像的概念以及基于 AdaBoost 算法训练人脸检测分类器的方法，并构建了第一个真正的实时人脸检测系统<sup>[23]</sup>。通过积分图计算特征值可以减少重复的计算，要得到每个特征的特征值只要遍历一次图像获得积分图即可。对于实时检测系统而言，使用能提高检测速度的积分图方法具有很大优势。

### 2.2.1 Haar-Like 特征

最初 Parageorgiou 提出使用 Haar 小波模板的方法来表示图像，它是一个自然集基函数，通过比较不同图像区域平均亮度的差别进行编码。随后 Paul Viola 等提出了 Haar-Like 特征，并将该特征引入人脸识别领域。Haar-Like 特征就是一种简单的矩形特征，因为它与 Haar 小波相似而得名 Haar-Like。Viola 在人脸检测系统中使用的四种基本矩形特征如图 2.1 所示。其中(a)、(b)是二矩形特征，(c)是三矩形特征，(d)是四矩形特征。二矩形特征的特征值为两个黑白区域内像素和之差，三矩形特征的特征值是中间矩形区域的像素和减去两侧矩形区域像素和之差，四矩形特征的特征值为两对角线区域像素和的差值。




图 2.1 Viola 使用的 4 种矩形特征

Fig.2.1 Four kinds of rectangle features used of Viola

随后，R.Lienhart 对 Haar-Like 特征进行了扩展，增加了一些垂直矩形特征和  $45^\circ$  矩形特征，扩展至 14 种，分为边缘特征、线状特征和中心包围特征。边缘特征主要反映图像边缘信息，线状特征主要反映图像线性方向信息，中心包围特征主要反映图像周围和中心特征信息的差异情况。这些特征除了水平方向和竖直方

向的特征以外，增加了  $45^\circ$  旋转方向的特征，并且它们通过增加加权值进行补偿并没有要求相邻矩形要具有相同的面积。扩展的 Haar-Like 特征如图 2.2 所示。




图 2.2 扩展的 Haar-Like 特征

Fig.2.2 Extended Haar-Like features

利用以上扩展的 Haar-Like 特征的组合能够有效的检测到图像局部特征的灰度变化。图 2.3 就直观的表现了 Haar-Like 特征在人脸图像上的实际分解情况。从左到右依次是原始图像和 Haar-Like 特征在人脸上的分解图像，人眼区域的灰度值要比下脸颊的灰度值低，眼睛区域要比两眼中间鼻梁区域灰度值更低。



图 2.3 人脸图像上的 Haar-Like 特征分解

Fig.2.3 Haar-Like decomposition on face image

### 2.2.2 积分图

引入积分图的目的是为了实现在多个不同尺度下，方便快速地计算分类器所需要的特征。Viola 和 Jones 的方法中，是将矩形特征作为分类依据。Haar-Like 特征的特征值计算直观来说是将矩形特征中白色区域和黑色区域的面积通过给定不同权重使得两部分区域面积相等然后求差，即通过计算得出矩形特征中白色区域的像素灰度值之和，并减去黑色区域的像素灰度值之和，得到其差值。用  $V$  表示特征值，即

$$V = S_{white} - S_{black} \quad (2-1)$$

在一个  $24 \times 24$  的检测窗口内，如果以简单的 4 种特征原型来穷举，则共有 45396 个大小不同以及在检测窗口中位置不同的矩形特征。如果以扩展的 14 种 Haar-Like 特征原型来穷举，则可得到 162336 个矩形特征。矩形特征的总数目远比该区域的像素数目大得多。一个如此小分辨率的图像都能得到庞大的特征数目，而训练样本又有很多，因此提高 Haar-Like 特征的计算速度非常必要。不同大小窗口对应的 Haar-Like 特征数目如表 2.1 所示。

表 2.1 不同大小窗口对应的 Haar-Like 特征数目

Table 2.1 The numbers of Haar-Like features in different windows

窗口大小	16×16	20×20	24×24	30×30	36×36
矩形特征数	32384	78460	162336	394729	816264


针对上述问题就引入了积分图像(Integral Image)的概念，它是一种新的图像表示方法。利用积分图计算特征值时，不管矩形特征的尺度如何都只需要遍历一次图像就可以得到，它只和矩形特征端点积分图有关。

对于一个输入的图像  $I$ ，像素  $(x,y)$  的积分图像值为：

$$ii(x,y) = \sum_{x' \leq x, y' \leq y} i(x',y') \quad (2-2)$$

即像素点  $(x,y)$  的积分  $ii(x,y)$  为该点到  $I$  左上角所构成的矩形区域的灰度值之和。

如图 2.4 所示，图中阴影部分的所有像素灰度值的和即为像素点  $(x,y)$  的积分

图 2.4 点  $(x,y)$  处的积分图像值Fig.2.4 Computation of integral image at point  $(x,y)$ 

有了积分图，就可以通过少量的简单计算来得到矩形特征。通过积分图上面所对应的四个点就可以得到任意一个矩形特征内的像素和，如图 2.5 所示






图 2.5 积分图的计算

Fig.2.5 Computation of integral image

$II_1$ 是矩形特征区域A的像素值的和, $II_2$ 是矩形特征区域A+B的像素值的和, $II_3$ 是矩形特征区域A+C的像素值的和, $II_4$ 是矩形特征区域A+B+C+D的像素值的和。所以矩形特征区域D中的像素和为

$$Sum(D) = (II_4 + II_1) - (II_2 + II_3)$$

这样只需要要经过逐点扫描输入图像  $I$  一次, 就可以把图像  $I$  的积分图给计算出来。记  $s(x, y) = \sum_{y' \leq y} i(x, y')$  是原图像  $(x, y)$  点所在列纵坐标下, 不超过该点坐标值的所有像素灰度值的和, 有下面的递推公式

$$\begin{cases} s(x, y) = s(x, y - 1) + i(x, y) \\ ii(x, y) = ii(x - 1, y) + s(x, y) \end{cases} \quad (2-3)$$

在进行多尺度检测时, 采用缩放特征模板的方法, 即便是在任意尺度搜索, 都可以使用这一个积分图像, 即在整个检查过程只需要扫描一遍原图, 这样既节约了时间, 又减少了重复的计算。

以图 2.6 为例说明根据积分图快速计算任意矩形区域的特征值的过程。




图 2.6 矩形特征值计算

Fig.2.6 Computation of the rectangle feature in integral image

根据定义, 特征值  $V = S_{white} - S_{black}$  可得:

$$S_{white} = (ii_4 + ii_1) - (ii_2 + ii_3)$$

$$S_{black} = (ii_6 + ii_3) - (ii_4 + ii_5)$$

所以，该矩形特征的特征值为

$$(ii_4 + ii_1) - (ii_2 + ii_3) - (ii_6 + ii_3) + (ii_4 + ii_5)$$

由于人脸图像中各种尺寸的人脸、眼睛以及嘴巴都有可能出现，所以需要逐层放大检测子窗口来检测图像，检测子窗口一般放大 1.1-1.25 倍。而通过积分图来计算，只需要知道放大的矩形子窗口的坐标，然后再通过积分图上的对应位置来查找积分值，最后经过简单的加减运算就可以得到检测窗口的 Haar 特征值。

## 2.3 AdaBoost 算法

### 2.3.1 AdaBoost 算法简介

AdaBoost 算法最初是起源于 1990 年 Schapire 提出的 Boosting 算法<sup>[24]</sup>, Boosting 算法是一种提高任意给定学习算法准确度的方法。Boosting 算法的思想是在 Valiant 提出的 PAC(Probably Approximately Correct)学习模型<sup>[25]</sup>的理论分析的基础上得来的。该套理论主要研究的内容是一个问题在什么时候是可被学习的以及学习算法等。随后 Valiant 和 Kearns 提出了弱学习(weak learning)和强学习(strong learning)的概念。在 PAC 学习模型中，如果某个学习算法识别一组概念的准确率仅比随机猜测略好，即识别准确率略高于 0.5，则称之为弱学习算法。如果某个学习算法能在多项式时间内识别一组概念，并且识别的准确率高，则称之为强学习算法。

因为强学习算法很难直接获得，Valiant 和 Kearns 提出了 PAC 学习模型中关于弱学习算法和强学习算法是否等价的问题，也就是说任何弱学习器算法如果比随机猜测略好，是不是就可以通过提升而成为强学习算法；如果两种学习算法等价，是不是就只需要找到一个比随机猜测略好的弱学习算法，并可以把它提升为强学习算法，而不再需要寻找很难直接获得的强学习算法。

Schapire 于 1990 年提出了一种多项式级的算法，并证明了该问题的正确性。这种算法即为最初的 Boosting 算法。随后, Freund 又提出了一种新的改进 Boosting 算法，使得算法的效率更高。Boosting 算法的目的是为了提高学习算法的分类准确率，根据训练样本来设计分类器(分类器的分类准确率要比平均性能好)，然后加入多个分类器，最后合成一个总的分类器。Boosting 算法在解决实际问题时存在着缺陷，它需要事先知道弱学习算法的学习正确性的下限，并且会存在过拟合

(overfitting)现象。Freund 和 Schapire 于 1995 年改进了 Boosting 算法并且利用倍增权重更新(Multiplicative weight-update)技术提出了 AdaBoost (Adaptive Boosting)<sup>[26]</sup>算法, 该算法的算法效率与 Freund 之前提出的 Boosting 算法效率几乎一致, 但是它不再需要任何关于弱学习器的先验知识, 因此更适用于解决实际的分类问题, 而且在机器学习领域中也得到了很高的重视。经过大量试验结果表明, AdaBoost 算法能大大提高泛化能力并且不易引起过拟合现象, 目前已经成为 Boosting 系列算法中使用最广泛的代表算法。Adaboost 有很多优点, 其优点如下:

- (1)精度高, 分类速度快;
- (2)不需要任何关于弱学习器的先验知识;
- (3)Adaboost 算法提供的是框架, 它可以兼容多种方法来构建弱分类器, 如决策树、神经网络等;
- (4)对弱分类器性能要求低, 弱分类器容易获得使得算法复杂度降低, 效率高;
- (5)训练数据多样化, 如文本、数字、离散值等等, 且算法易于多类目标分类问题的推广;
- (6)不易出现过拟合现象。

### 2.3.2 AdaBoost 算法原理描述

AdaBoost 实质上是一种迭代算法, 其核心思想是针对同一训练集训练出不同的分类器—弱分类器, 然后, 把这些弱分类器集合起来, 构建成一个更强的分类器。AdaBoost 算法的本质是通过改变数据分布来实现的, 它每个样本的权重则是根据每次训练集中样本分类是否正确, 以及上轮训练中样本总体分类的准确率来确定的。并用修改过权重的新数据进行下层分类器的训练, 最后把每次训练得到的分类器融合起来, 就得到最终的决策分类器。在 AdaBoost 算法具体实现时, 最初给每个样本赋予相同的权重(说明样本被选入弱分类器的概率相等), 在该样本分布下训练弱分类器。对于分类错误的样本, 增加它的样本权重, 使得它选入训练集的概率增加; 对于分类正确的样本, 则降低它的样本权重, 使它选入训练集的概率降低。这样会得到一个新的样本分布, 该样本分布会使分类错误的样本更加突出, 然后用新的样本集训练下一个弱分类器。随后根据分类的错误率赋予训练的弱分类器以相应的权重, 来表示该弱分类器的重要程度。训练过程依次循环, 历经  $T$  次迭代, 就会得到  $T$  个弱分类器及其对应的权重, 最后将  $T$  个弱分类器按

权重累加就能获得最终的强分类器。

弱分类器构造为：矩形特征  $j$  对应着一个弱分类器  $h_j$ ， $x$  表示一个候选输入图片样本子窗口， $f_j(x)$  表示  $j$  在  $x$  上的特征值，弱分类器的公式定义如下：

$$h_j(x) = \begin{cases} 1, & p_j f_j(x) < p_j \theta_j \\ 0, & \text{else} \end{cases} \quad (2-4)$$

其中  $p_j = \pm 1$ ，是可以控制不等式方向的方向指示符（对于不同得到特征，计算出来的特征值中有可能负样本的特征值小于正样本的特征值，也可能负样本的特征值大于正样本的特征值，正样本特征值也未必小于区分正负样本的阈值，因此引入一个指示符来控制不等式的方向）。 $\theta_j$  是特征  $j$  对应分类器的阈值，对每一个特征选取一个最优阈值  $\theta_j$  使得对应的分类误差  $\varepsilon_j$  最小。

AdaBoost 算法具体步骤如下：

(1) 给定训练样本集：  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ ， $x_i \in X$ ， $y_i \in Y = \{+1, -1\}$ ， $Y$  表示样本类别，即正样本和负样本。 $i = 1, 2, \dots, n$ ， $n$  是训练样本的数量。

(2) 初始化权重：在训练集上的每个样本初始时假设为均匀分布，即对应的权重是相等的。 $U_t(i) = \frac{1}{n}$ ， $(i = 1, 2, \dots, n)$ ， $U_t(i)$  表示在第  $t$  轮迭代时赋给样本  $(x_i, y_i)$  的权重。

(3) 在当前权重分布下，针对每个特征训练一个弱分类器并选出错误率最低的作为此次迭代的弱分类器  $h_j$ ，经过  $T$  轮迭代，选出  $T$  个弱分类器。

a. 归一化样本权重：

$$U_t(i) = \frac{U_t(i)}{Z_t} \quad (2-5)$$

其中  $Z_t = \sum_i U_t(i) e^{(-\alpha_t y_i h_t(x_i))}$ ， $Z_t$  用来保证  $U_{t+1}(i)$  是概率分布的归一化因子

b. 对于每个特征  $j$ ，计算训练的弱分类器  $h_j$  对应的加权错误率  $\varepsilon_j$ ：

$$\varepsilon_j = \sum_{y_i \neq h_j(x_i)} U_t(i) = \sum_{i=1}^n U_t(i) |h_j(x_i) - y_i| \quad (2-6)$$

当  $\varepsilon_j \geq \frac{1}{2}$  时，本轮迭代结束。

c. 遍历所有特征和弱分类器，并选择一个具有最小加权错误率  $\varepsilon_j$  的弱分类器  $h_t$

作为最优弱分类器，并把最小加权错误率记为 $\varepsilon_t$ 。

d. 为下次迭代更新样本权重：

$$\begin{aligned} U_{t+1}(i) &= U_t(i) \times \begin{cases} e^{-\alpha_t}, h_t(x_i) = y_i \\ e^{\alpha_t}, h_t(x_i) \neq y_i \end{cases} \\ &= U_t(i) e^{(-\alpha_t y_i h_t(x_i))} \\ &= U_t(i) \beta^{-e_i} \end{aligned} \quad (2-7)$$

其中 $\beta_t = \sqrt{\frac{1-\varepsilon_t}{\varepsilon_t}}$ ，如果样本分类正确 $e_i = 1$ ，样本分类错误 $e_i = -1$ 。

e. 把经过 T 轮迭代后得到的 T 个最优弱分类器组合成一个强分类器：

$$H(x) = \begin{cases} 1, & \sum_{t=1}^T \alpha_t h_t(x) \geq \frac{1}{2} \sum_{t=1}^T \alpha_t \\ 0, & \text{else} \end{cases} \quad (2-8)$$

其中 $\alpha_t = \ln \beta_t$ ， $\alpha_t$ 是在第 T 轮迭代是所产生的弱分类器 $h_t$ 在组合的强分类器 $H(x)$ 中的加权参数，它是对弱分类器的性能评价因子。加权参数 $\alpha_t$ 是弱分类器的加权错误率 $\varepsilon_t$ 的递减函数， $\varepsilon_t$ 越小， $\alpha_t$ 就越大，说明弱分类器的性能越好，分类能力越强，越重要。

### 2.3.3 AdaBoost 算法性能分析

在 AdaBoost 算法的弱学习中，记弱分类器的错误率为 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_T$ ，记强分类器 $H(x)$ 的误判率为 $E(H)$ 。如果每个弱分类器的错误率 $\varepsilon_t < \frac{1}{2}$ ，则强分类器的误判率 $E(H) < 2\sqrt{\varepsilon_t(1-\varepsilon_t)}$ <sup>[27]</sup>。

证明过程如下：

$$\begin{aligned} U_{t+1}(i) &= \frac{U_t(i) e^{(-\alpha_t y_i h_t(x_i))}}{Z_t} \\ &= \frac{e^{-y_i \sum_{t=1}^T \alpha_t h_t(x_i)}}{\prod_{t=1}^T Z_t} \end{aligned} \quad (2-9)$$

令 $f(x) = \sum_{t=1}^T \alpha_t h_t(x)$

$$U_{t+1}(i) = \frac{e^{-y_i f(x_i)}}{\prod_{t=1}^T Z_t} \quad (2-10)$$

因为权重 $U(i)$ 是归一化的概率分布，所以

$$\sum_{i=1}^m U_{t+1}(i) = 1$$

$$U_{t+1}(i) = \frac{e^{-y_i f(x_i)}}{m \prod_{t=1}^T Z_t} \quad (2-11)$$

得出

$$\prod_{t=1}^T Z_t = \frac{1}{m} \sum_{i=1}^m e^{-y_i f(x_i)} \quad (2-12)$$

强分类器  $H(x)$  对训练样本集的误判率  $E(H)$  为

$$\begin{aligned} E(H) &= \frac{1}{m} \sum_{i=1}^m \begin{cases} 1, & \text{if } y_i \neq h(x_i) \\ 0, & \text{else} \end{cases} \\ &= \frac{1}{m} \sum_{i=1}^m \begin{cases} 1, & \text{if } y_i f(x_i) \leq 0 \\ 0, & \text{else} \end{cases} \\ &\leq \frac{1}{m} \sum_{i=1}^m e^{-y_i f(x_i)} \\ &= \prod_{t=1}^T Z_t \end{aligned} \quad (2-13)$$

要使误判率快速下降

$$Z_t = \sum_{i=1}^m U_t(i) e^{(-\alpha_t y_i h_t(x_i))}$$

$Z_t$  是归一化因子, 求  $Z_t$  的最小值

$$\begin{aligned} Z_t &= \sum_{i=1}^m U_t(i) e^{(-\alpha_t y_i h_t(x_i))} \\ &= \sum_{y_i=h(x_i)} U_t(x_i) e^{-\alpha_t} + \sum_{y_i \neq h(x_i)} U_t(x_i) e^{\alpha_t} \\ &= (1 - \varepsilon_t) e^{-\alpha_t} + \varepsilon_t e^{\alpha_t} \end{aligned} \quad (2-14)$$

对  $\alpha_t$  进行求导, 求得  $Z_t$  的局部最小值

$$\frac{dZ_t}{d\alpha_t} = -(1 - \varepsilon_t) e^{-\alpha_t} + \varepsilon_t e^{\alpha_t} \quad (2-15)$$

令  $\frac{dZ_t}{d\alpha_t} = 0$ , 解得

$$\alpha_t = \frac{1}{2} \ln \frac{1-\varepsilon_t}{\varepsilon_t} \quad (2-16)$$

所以

$$\begin{aligned} Z_t &= (1 - \varepsilon_t) e^{-\alpha_t} + \varepsilon_t e^{\alpha_t} \\ &= (1 - \varepsilon_t) e^{-\frac{1}{2} \ln \frac{1-\varepsilon_t}{\varepsilon_t}} + \varepsilon_t e^{\frac{1}{2} \ln \frac{1-\varepsilon_t}{\varepsilon_t}} \end{aligned} \quad (2-17)$$

$$\begin{aligned}
&= (1 - \varepsilon_t) \sqrt{\frac{\varepsilon_t}{(1 - \varepsilon_t)}} + \varepsilon_t \sqrt{\frac{(1 - \varepsilon_t)}{\varepsilon_t}} \\
&= 2\sqrt{\varepsilon_t(1 - \varepsilon_t)}
\end{aligned}$$

记  $\varepsilon_t = \frac{1}{2} - \gamma_t$ ，因为弱分类器的错误率要比随机猜测错误率好，即  $\varepsilon_t > \frac{1}{2}$ ，所以  $0 < \gamma_t < \frac{1}{2}$ 。

代入上式得

$$Z_t = 2\sqrt{\left(\frac{1}{2} - \gamma_t\right)\left(\frac{1}{2} + \gamma_t\right)} = \sqrt{1 - 4\gamma_t^2} \leq \sqrt{e^{-4\gamma_t^2}} = e^{-2\gamma_t^2} \quad (2-18)$$

$$E(H) \leq \prod_{t=1}^T Z_t = -2 \sum_{t=1}^T \gamma_t^2 \quad (2-19)$$

由上述推导过程可看出，强分类器的误判率  $E(H)$  随着训练次数  $T$  和弱分类器错误率的下降呈指数型函数递减，即随着弱分类器数量的增加，强分类器的误判率迅速降低。因此从理论上来讲，只要弱分类器有足够多的数量，强分类器的误判率可以降低至任意水平。

### 2.3.4 级联分类器原理

由 AdaBoost 算法的特点可知，强分类器的工作原理是，先让弱分类器对训练样本进行检测，就相当于先让所有弱分类器进行投票，再按照弱分类器对应的错误率对投票结果加权求和，然后将求和结果与平均投票结果相比较，最终输出检测的结果。平均投票结果是指当全部弱分类器检测结果出现概率相同的情况下的概率平均值。可以利用增加算法的迭代次数来提高算法检测的准确率，从而使得强分类器的误差尽量小。但是随着迭代次数的增加，生成的弱分类器的数目也在增加，算法的计算量就会变大。这样严重影响了算法检测的效率，算法检测效率降低就很难达到应用中实时检测的目标。所以，为了提高检测性能，加快检测速度，采用级联分类器的方法。

Viola 等利用 AdaBoost 算法进行人脸检测时达到实时的检测速度主要有两方面的原因，一个是通过使用积分图快速计算特征值，另一个重要原因就是利用了多个分类器级联的方法。级联分类器实际就是一种多层的分类器结构，开始前几层分类器使用的特征数目少且结构比较简单，越往后弱分类器特征数目就会越来越多，检测精度也会越来越高，这样使得能够通过各层分类器的待检测的子窗口

越来越少，最后达到提高检测速度的目的。利用级联的分类器对待检测的样本进行分类时，只有当前一层的分类器分类正确的样本才能进入下一层分类器，而分类错误的样本直接被排除输出。最后，通过每一层分类器的样本才作为最后的正样本。级联分类器结构如图 2.7 所示。

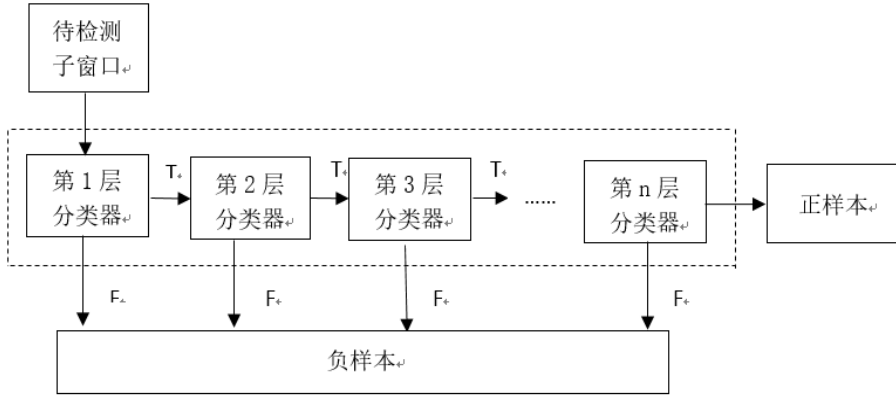


图 2.7 级联分类器结构图

Fig.2.7 Structure of cascade classifier

图 2.7 中，T 表示该层分类器判断其是正样本，F 表示判断是负样本。在级联分类器的多层结构中，其每层的分类器都是通过 AdaBoost 算法训练得来的。结构中前面的几层分类器结构简单并且使用的特征数也较少，但是它们却能够把大量的与目标样本差异大的负样本给剔除掉，有着很高的检测率。后面的几层分类器使用更多的特征和复杂的结构来区分与目标样本差异较小的负样本，很大程度的降低了虚警率。在实际应用的目标检测问题中，通常正样本所占待检测样本整体比重较小，而负样本在级联分类器结构的前端部分就被剔除掉了大多数，因此需要通过所有层级分类器的样本只占少数，所以级联结构能显著提高分类器的检测率，同时还大大降低了运算量。

### 2.3.5 级联分类器构造算法

给定一个级联分类器，误识率为：

$$F = \prod_{i=1}^N f_i \quad (2-20)$$

其中， $N$  是分类器的层数， $f_i$  是第  $i$  层强分类器的误识率。误识率（或称误判率、虚警率）是指在训练中被错误分类为正样本的负样本数量占所有待检测正样本数量的比例。

级联分类器的检测率为：

$$D = \prod_{i=1}^N d_i \quad (2-21)$$



其中,  $d_i$  是第  $i$  层强分类器的检测率。检测率是指分类正确的正样本数量占实际待检测正样本数量的比例。

由以上公式可以看出, 要训练级联分类器的检测率和误识率, 只需要分别训练多层分类器的每个阶段的检测率和误识率即可。例如, 如果想要级联分类器的最终检测率达到 90%, 就可以用 10 层每层有 99% 的检测率的强分类器 ( $0.9 \approx 0.99^{10}$ ) 得到。如果想要其误识率达到 0.0006%, 可以用每层误识率有 30% 的强分类器 ( $6 \times 10^{-6} \approx 0.3^{10}$ ) 得到。每层分类器的检测率和误识率都在该层分类器的学习过程中达到, 所以, 构造级联分类器关键问题是怎样使每层的强分类器的检测率提高到  $d_i$ , 误识率降低到  $f_i$ 。

通过 Adaboost 算法训练得到的强分类器一般具有较低的错误率, 但检测率却不高。通常情况下, 高检测率的同时伴随出现的是高误识率, 从而导致错误率的增加。如果想要提高某一层分类器的检测率, 一个方便有效的方法就是降低分类器的阈值。如果要降低某一层分类器的误识率, 同样的方法是提高分类器的阈值。这与提高分类器的检测率相矛盾。提高检测率、降低误识率可以通过增加弱分类器的数量来实现, 但是这样会使检测时间变长, 影响检测速度。所以, 构造级联分类器有两大问题: 如果增加弱分类器的数量, 那么在降低误识率的同时又增加了检测时间; 如果通过降低强分类器的阈值来实现检测率的提高, 那么就会出现误识率增加的现象。所以在构造级联分类器时要注意衡量检测率和误识率的平衡

首先, 确定每层分类器的最大的可接受的误识率和最小需要达到的检测率以及最终的级联分类器的误识率。其中级联分类器结构的的每一层分类器都是用 AdaBoost 方法来训练所得到的, 每层分类器所用的特征数目不停地增加, 直到达到预期定好的检测率和误识率。通过在分类器上对样本集进行测试得出实验检测率和误识率。如果该层分类器的检测率没有达到指定要求, 那么就降低该层分类器的阈值, 然后再重新测试该层分类器的检测率和误识率。如果该层分类器的误识率没有达到预期要求, 则再多加一层分类器。下面给出级联分类器机构的具体算法:

(1) 设每层分类器的最大误识率为  $f$ , 最小检测率为  $d$ , 最终的级联分类器的误识率为  $F$ , 正样本集为  $P$ , 负样本集为  $N$ 。

(2)初始化 $F_0 = 1$ ,  $d_i = 1$ ,  $i = 0$ 。

(3)While  $F_i > F$

a.用训练样本集  $P$  和  $N$  训练第  $i$  层的多个弱分类器，一直到组合的强分类器的误识率 $f_i \leq f$ 且检测率 $d_i \geq d$ 为止；

b. $i \leftarrow i + 1$ ,  $F_i \leftarrow f_i F_i$ ,  $N \leftarrow \emptyset$ ;

每层的强分类器都要依据  $d$  和  $f$ ，当不满足 $f_i \leq f$ 且 $d_i \geq d$ 时，可以通过降低强分类器的阈值提高检测率，或是增加分类器层数即增加弱分类器数目来降低误识率的方法来进行调整，但一定要同时衡量该层分类器的检测率和误识率。

### 2.3.6 级联分类器检测流程

使用级联分类器对待检测图像或视频图像进行目标检测的流程大致可以分为三步，逐层放大尺寸、级联检测、重复检测归并。

(1)逐层放大尺寸过程

由于检测子窗口在检测过程中的尺寸是固定的，而待检测图像中的检测目标尺寸是未知的，所以为了能够实现多种尺寸的目标检测，就需要检测子窗口多次进行检测。并且在检测过程中，逐层来放大待检测窗口，再使用多种尺寸的检测子窗口对整个待检测图像进行遍历。

如果用初始大小为  $20 \times 20$  的检测子窗口来检测一张  $640 \times 480$  像素的图像，将子窗口以 1.25 的放大倍数进行逐层放大，这样放大 23 次以后，才能实现在  $640 \times 480$  的图像上对  $20 \times 20$  到  $480 \times 480$  尺寸大小的目标进行检测。

(2) 级联检测过程

级联分类器由多个强分类器串联组成。在检测过程中，每次对应不同尺寸的子窗口，初始的检测子窗口尺寸和待检测图像的尺寸决定了检测的次数。在每次检测前，让子窗体从上至下、从左至右地遍历整个待检测图像，在待检测图像上得到子窗体对应的图像集，并将图像集作为样本集来进行检测。当一级强分类器检测结束后，会把非目标图像的子窗体剔除，而把剩下的图标图像的子窗体所对应的图像集作为下一轮检测的样本集。

级联分类器的整体结构就像一个递减结构的决策树。每一层强分类器检测后得到的目标集合来触发下一层分类器的检测，依次类推。依次检测每个不同尺寸的子窗体对应的样本集，目标图像的子窗体在每次检测时都要通过每层强分类器，

而非目标图像子窗体则在被检测时的那层强分类器中就被剔除。经过多轮检测，大多数的非目标图像都在分类器中被剔除，最后得到目标图像。

### (3) 重复检测归并过程

按照以上方法对目标进行检测，会出现在临近的位置和尺寸上同一个目标被多次检测的情况，这种现象叫重复检测。针对重复检测的结果可以对其进行归并。

如果目标子窗体都在指定的邻域内存在，则把他们都看做是同一目标，并且该目标窗口的尺寸大小平均值和领域的大小成正比。以下是具体的归并过程：

a.确定领域窗口，邻域窗口由子窗口的大小确定，然后记录子窗口所在位置的中心点坐标。

b.用邻域窗口从上至下、从左至右的遍历图像，在一个相同的目标中心点集中把在邻域窗口内包含的全部的中心点归类在一起。

c.计算中心点坐标的平均值，把该值作为归并目标的中心点。同时，归并目标的宽和高也就是计算同一目标的多个子窗口的宽和高的平均值。这样就将多个目标归并为了一个检测结果。

## 2.4 人脸检测实验结果

本章节使用静态图片集对传统的 AdaBoost 算法进行了简单实验。在后续章节会详细介绍基于 AdaBoost 算法的人脸检测和人眼检测的实验流程。使用 Adaboost 算法进行的人脸检测实验结果如图 2.8 所示。



图 2.8 AdaBoost 算法的人脸检测结果

Fig.2.8 Experimental results of Face detection based on Adaboost algorithm

因为人脸的特征比较丰富，而且特征相对稳定，所以通过 AdaBoost 算法进行人脸检测有较高的准确率。

## 2.5 本章小结

本章介绍了主要的人脸检测方法,选择基于统计学习的 AdaBoost 算法来作为本文的检测算法。先介绍了矩形特征和积分图,然后对 AdaBoost 算法的基本原理、性能进行了理论分析,在此基础上进一步介绍了算法中运用的级联分类器结构,分析了级联分类器的构造算法和检测流程。最后,基于传统 AdaBoost 算法进行了人脸检测实验,验证了该算法有较高的检测率。

## 第 3 章 基于改进的 AdaBoost 算法的人眼检测

### 3.1 AdaBoost 算法的退化现象

AdaBoost 采用迭代的计算原理,其算法的核心部分采用不同的训练集对同一个分类器(弱分类器)进行训练,然后把每一个训练集上得到的分类器整合到一起,构成一个性能更好最终分类器(强分类器)。在开始对分类器进行训练的时候,每个正负样本被赋予了同等的初始权重,并且采用这个样本对弱分类器进行训练。当某一轮弱分类器训练完成后,根据分类结果对正负样本权重进行调整,对于分类错误的样本,增加它的样本权重,使它在下一轮迭代时选入训练集的概率增加;对于分类正确的样本,则降低它的样本权重,使它在下一轮迭代时选入训练集的概率降低。这样会得到一个新的样本分布,新的样本分布在训练下一轮弱分类器时会更加关注分类错误的样本。但是随着增加迭代的次数,Adaboost 算法的重心就会逐渐转移,即会逐渐转移到较难分类的样本上。这样就会使困难样本的权重在样本集中的权重严重扩张。如果困难样本的权重过大,那么每次迭代时弱分类器都会对它提高重视,重视程度也不断增大,同时简单样本也就是之前分类正确的样本的权重在样本集中就会严重下降,使得算法的检测率降低,产生退化现象。同时,AdaBoost 算法对于困难样本中的正负样本并没有加以区分,这样也影响了正样本的检测率,而 AdaBoost 算法对于正确识别正样本要比正确识别负样本有更高的价值。

### 3.2 AdaBoost 算法的改进

为了减缓困难样本权重的过度扩张现象导致的退化现象,同时也提高算法对正样本的检测率,本文对传统的 AdaBoost 算法进行了改进。在算法中引入样本状态识别标记并利用新的样本权重更新方法来训练分类器,在保证原有 AdaBoost 算法关注困难样本的基础上增加被错误分类为负样本的正样本的权重,使算法更加关注于困难样本中的正样本,这样得以提高正样本的检测率,又通过使用弱分类器的动态加权参数,进一步加快算法的收敛,达到改进 AdaBoost 算法的目的。

改进的算法具体步骤如下:

(1)给定训练样本集:  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ ,  $x_i \in X$ ,  $X$  表示训练样本集;  
 $y_i \in Y = \{+1, -1\}$ ,  $Y$  表示样本类别;  $g_i \in G = \{+1, -1\}$ ,  $G$  表示样本识别状态。  
 $i = 1, 2, \dots, n$ ,  $n$  是训练样本的数量。

(2)初始化权重: 在训练集上的每个样本初始时假设为均匀分布, 即对应的权重是相等的。 $U_t(i) = \frac{1}{n}$ ,  $(i = 1, 2, \dots, n)$ ,  $U_t(i)$  表示在第  $t$  轮迭代时赋给样本  $(x_i, y_i)$  的权重,  $g_i = +1$ 。

(3)在当前权重分布  $U_t$  下, 针对每个特征利用  $g_i = +1$  训练一个弱分类器并选出错误率最低的作为此次迭代的弱分类器  $h_j$ , 经过  $T$  轮迭代, 选出  $T$  个弱分类器。

循环: for  $t = 1, 2, \dots, T$

a.归一化样本权重:

$$U_t(i) = \frac{U_t(i)}{Z_t} \quad (3-1)$$

其中  $Z_t = \sum_i U_t(i) e^{(-\alpha_t y_i h_t(x_i))}$ ,  $Z_t$  用来保证  $U_{t+1}(i)$  是概率分布的归一化因子

b.对于每个特征  $j$ , 计算训练的弱分类器  $h_j$  对应的加权错误率  $\varepsilon_j$ :

$$\varepsilon_j = \sum_{y_i \neq h_j(x_i)} U_t(i) = \sum_{i=1}^n U_t(i) |h_j(x_i) - y_i| \quad (3-2)$$

当  $\varepsilon_j \geq \frac{1}{2}$  时, 本轮迭代结束。

c.遍历所有特征和弱分类器, 并选择一个具有最小加权错误率  $\varepsilon_j$  的弱分类器  $h_t$  作为最优弱分类器, 并把最小加权错误率记为  $\varepsilon_t$ 。

d.识别正确的正样本的权重和

$$R_t = \sum_{y_i=1, h_t(x_i)=1} U_t(i) \quad (3-3)$$

e.求弱分类器  $h_t$  的加权参数<sup>[28]</sup>

$$\alpha_t = \ln \beta_t + \mu \times \frac{R_t}{v} \quad (3-4)$$

其中,  $v$  是全部正样本的权重和,  $\mu$  是常数, 一般取 0.001~0.01。

f.更新样本识别状态:

循环: for  $t' = 1, 2, \dots, n$

if  $h_t(x_i) = 1 \& y_i = -1$ ;

$g_i = -1$ ;

endif

g. 为下次迭代更新样本权重:

$$U_t(i) = \frac{U_t(i)}{Z_t}$$

$$Z_t = \sum_{g_i=+1} U_t(i) e^{(-\alpha_t y_i h_t(x_i))} \quad (3-5)$$

其中 $Z_t$ 是归一化因子。

$$U_{t+1}(i) = U_t(i) \times \begin{cases} \beta_t^{-1} & y_i = h_t(x_i) \\ \beta_t^{\frac{1}{2}} & y_i \neq h_t(x_i), y_i = -1 \\ \beta_t^{\frac{2}{3}} & y_i \neq h_t(x_i), y_i = 1 \end{cases} \quad (3-6)$$

其中 $\beta_t = \sqrt{\frac{1-\varepsilon_t}{\varepsilon_t}}$ 。

h. 把经过 T 轮迭代后得到的 T 个最优弱分类器组合成一个强分类器:

$$H(x) = \begin{cases} 1, & \sum_{t=1}^T \alpha_t h_t(x) \geq \frac{1}{2} \sum_{t=1}^T \alpha_t \\ 0, & \text{else} \end{cases} \quad (3-7)$$

$\alpha_t$ 是在第 T 轮迭代是所产生的弱分类器 $h_t$ 在组合的强分类器 $H(x)$ 中的加权参数。

改进后的 AdaBoost 算法首先对于要训练的样本,在初始时增加样本识别状态标记,记为 $g_i = +1$ 。在后面的迭代过程中,如果某负样本在本轮训练过程中分类正确,则改变识别状态即 $g_i = -1$ ,该正确分类的负样本将不参与下一轮的训练。在样本更新和归一化权重时已经被正确分类的负样本不作考虑,这样可以缓冲困难样本权重过分扩张的现象。与此同时,引入新的弱分类器加权参数,使得在困难样本中的正样本权重增加得比负样本快。在新的弱分类器加权参数中, $R_t$ 代表了识别正确的正样本的权重,即是弱分类器对于正样本的识别能力。其中 $\mu \times \frac{R_t}{v}$ 是 $R_t$ 的增函数,所以 $R_t$ 越大,说明弱分类器对正样本的识别能力就越强,因此加权参数 $\alpha_t$ 也就越大。当错误率相同时,如果弱分类器对正样本具有更高的识别能力,那么它就具有更大的权重,因而能够加快训练过程的收敛,得以提高检测的精确度。当归一化样本权重后,在下一轮迭代时正样本的概率变大,说明正样本在训练过程中受到了更多的关注,这样提高了正样本的识别能力同时达到了减缓了困

难样本中负样本权重的过分扩张现象的目的。

### 3.3 构造人脸-人眼分类器进行人眼检测

通过分析可知,用于人脸检测的 AdaBoost 算法同样适用于人眼检测,只要在训练样本时用人眼样本图像集代替人脸样本图像集,其他流程均和人眼检测相同。但是经验证,使用 AdaBoost 算法直接进行人眼检测时,虽然通常情况下都可以检测出人眼,但是也常会出现把背景中的其他物体误识为人眼的情况,比如由于眼睛和嘴巴轮廓形状比较相似,多数情况下人眼分类器会误判,导致检测误识率高。通过前面对级联分类器的误差分析,我们可以得出无法做到在提高检测率的同时降低误识率。只对人眼进行训练和分类很难满足实际检测的要求,所以本文使用人脸-人眼分类器检测的方式来进行人眼的检测。

#### 3.3.1 人眼粗定位

人脸检测完成后,就要在检测出的人脸区域检测人眼,在整个人脸区域中检测人眼,检测的计算量比较大。如果能在人脸区域上缩小人眼检测的候选区域,粗定位人眼,把人眼检测的候选区域降到尽量小,就能减少检测计算量、提高检测速度。

根据人脸结构的“三庭五眼”准则进行人眼在人脸区域上的粗定位。其中,“三庭”指的是脸的长度比例,把脸长分成三等份,从前额发际线到眉骨、从眉骨到鼻翼下缘、从鼻翼下缘到下巴底端<sup>[28]</sup>,上中下各占脸长度的  $\frac{1}{3}$ 。“五眼”指的是脸的宽度比例,把脸宽分成五等份,从左侧发髻到右侧发髻,为五只眼睛的宽度,其中两只眼睛中间有一只眼睛的距离,两眼外侧到两侧发髻各为一只眼睛的距离,各占脸宽度的  $\frac{1}{5}$ 。人脸结构的“三庭五眼”准则如图 3.1 所示。




图 3.1 人脸“三庭五眼”准则

Fig. 3.1 Standard of three court five eyes



在检测出人脸区域以后，可以根据“三庭五眼”准则来粗定位人眼区域的大致范围，再用训练好的人眼分类器在该区域进行人眼检测。使用这种先缩小区域搜索再结合分类器检测的方法可以快速定位出人眼，能够提高检测速度，也能很大程度的降低眼睛的误识率，同时也提高了检测的精度。

### 3.3.2 构造人脸-人眼分类器

人脸-人眼分类器是由人脸分类器和人眼分类器的级联过程。首先，从视频图像里获取一帧图像，经过人脸分类器进行人脸检测，将检测出的人脸区域根据“三庭五眼”的结构进行粗定位，把粗定位的大致区域图像再送入人眼分类器进行检测，最后检测出人眼区域图像。人脸-人眼分类器结构如图 3.2 所示。

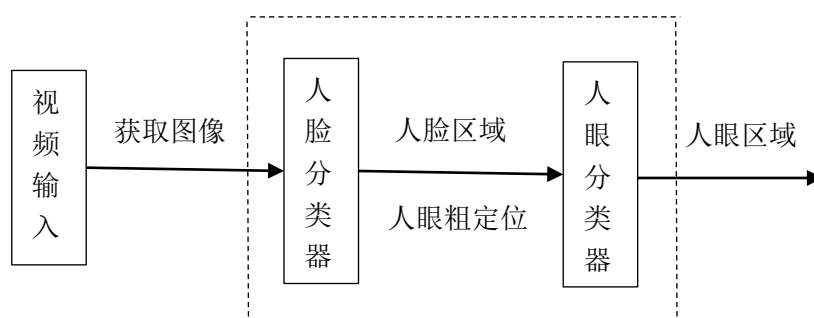


图 3.2 人脸-人眼分类器结构

Fig. 3.2 Construct of face-eye classifier

人脸-人眼双层 AdaBoost 分类器的结构能够有效的抑制人眼的误识率。因为人脸的特征比较丰富，而且特征相对较固定，所以使用 AdaBoost 算法训练人脸样本时，可以使用较高的阈值同时还有较高识别率。通常 AdaBoost 算法的人脸检测误识率很低。这样通过检测到的人脸区域进行人眼检测，可以解决直接用 AdaBoost 算法进行人眼检测的误识率低的问题，在减小误识率的同时还有较高的检测率。

## 3.4 人眼检测实验结果及分析

### 3.4.1 OpenCV 简介

Open CV (Open Source Computer Vision Library) 是一个跨平台计算机视觉数据库，这一数据库是基于开源发行的并由 Intel 公司提供支持。这一视觉数据库主要是由一系列 C 函数以及一部分 C++ 类来构成，同时也提供了 JAVA、Python、Ruby、Matlab 等语言的接口，这个计算机视觉数据库可以同时 Linux 系统、

Windows 系统以及 Mac OS 操作系统上运行。它由于事先封装好了各种如灰度化、直方图、直方图均衡化、机器学习等图形图像处理的算法而受到图形图像开发者的喜爱。Intel 公司开发 Open CV 的目的是为了促进 CPU 的密集型应用，并且可以让计算机视觉领域的开发者可以不用从底层开始构造函数而是直接在以前的基础上进行研究。Open CV 有以下特点<sup>[29]</sup>：

(1)开源性代码，无论是商业还是非商业用途，都可以免费使用 OpenCV 源代码或者进行修改进行二次开发 OpenCV，还可以将修改的代码加入代码库中共享给别人一起使用。

(2)预先封装好了很多图形图像处理的算法，给开发者提供了很多的便利。

(3)具有可重写的结构和功能。

(4)与 Intel 处理器架构相兼容，具有强大的图像和矩阵运算能力即有强大的图形图像处理功能。

(5)具有友好简明的用户接口和良好的函数封装性。

本文在 Visual Studio 2008 环境下，结合开源图像处理包 OpenCV 来对检测系统进行编程实现。

### 3.4.2 训练样本集和预处理

Adaboost 算法的检测效果关键在于前期样本训练的弱分类器的选择，弱分类器的选择又在很大程度上取决于样本集的选择，所以前期训练样本集也是很重要的工作。

人脸图像数据库主要作用除了对人脸检测算法进行训练外，还可以对其进行测试。目前，广泛应用于人脸检测和识别的人脸图像数据库如表 3.1 所示。这些人脸数据库一般是针对特定的检测算法来建立的，所以在进行人脸检测时要选取合适的人脸数据库中的人脸图像集并对其进行适当处理。

表 3.1 常用的人脸数据库

Table 3.1 The commonly used face database

数据库名称	位置	描述
麻省理工学院 MIT 数据库	<a href="ftp://whitechapel.media.mit.edu/pub/images">ftp://whitechapel.media.mit.edu/ pub/images</a>	由 16 个人的人脸图像, 每个人有 27 幅在不同光线、不同尺度、不同头部角度情况下的图像
MIT CBCL(生物和计算学习中心)数据库	<a href="http://www.ai.mit.edu/projects/cbcl/software-datasets/FaceData2.html">http://www.ai.mit.edu/projects/ cbcl/software-datasets/FaceD ata2.html</a>	包含 6977 幅图像(2429 幅人脸图像, 4548 幅非人脸), 测试集包含 24045 幅图像(472 幅人脸图像, 23573 幅非人脸图像)
英国 AT&T 数据库	<a href="http://www.uk.research.att.com">http://www.uk.research.att.com</a>	由 40 个人的 400 幅灰度图像组成, 人脸脸部表情和细节均有变化, 人脸姿态也有所变化
美国 FERET 数据库	<a href="http://www.nist.gov/humanid/feret">http://www.nist.gov/humanid/ feret</a>	包含大量的人脸图像, 由美国军方研究实验室提供, 其中每个人 8 张图像, 两张正脸, 3 张从右到左不同侧面角度的照片, 还有更多不同视点和表情的图像
伯尔尼大学 Bern 数据库	<a href="ftp://ianftp.unibe.ch/pub/images/faceimages/">ftp://ianftp.unibe.ch/pub/images/ faceimages/</a>	由 30 个人的 300 幅正面人脸图像(每人 10 幅)和 150 幅侧面人脸图像(每人 5 幅)组成
耶鲁大学 Yale 数据库	<a href="http://cvc.yale.edu">http://cvc.yale.edu</a>	由 16 个人每人 10 幅正面人脸图像组成, 人脸表情及光照条件均有变化
普渡大学 AR 数据库	<a href="http://rv11.ecn.purdue.edu/~aleix/aleix_face_db.html">http://rv11.ecn.purdue.edu/~aleix/ aleix_face_db.html</a>	由 126 个人的约 4000 幅左右的彩色人脸图像组成, 人脸表情、面部装饰及光照条件均有变化
中国 CAS-PEAL 数据库	<a href="http://www.jdl.ac.cn/peal/index.html">http://www.jdl.ac.cn/peal/index. html</a>	公开的数据库包括 1040 个人的 30871 幅图像, 表情、姿态、光照以及饰物均有变化

本文使用的人脸样本包括 BioID 人脸库和部分 MIT、ORL 人脸库中的人脸和非人脸图像。人脸训练样本 2500 多张，非人脸训练样本 2300 多张。部分人脸图像样本如图 3.3，部分非人脸样本如图 3.4。



图 3.3 部分人脸样本

Fig.3.3 Part of face samples




图 3.4 部分非人脸样本

Fig. 3.4 Part of no-face samples

由于目前没有公开的人脸数据库，所以就从 BioID 人脸库中截取出人眼区域作为人眼训练样本，把去掉人眼区域之外的剩余部分和一些从互联网上下载的非人眼图像作为非人眼样本。其中部分人眼样本如图 3.5 所示。



图 3.5 部分人眼样本

Fig.3.5 Part of eye samples

然后对选取的图像样本集进行预处理，对样本图像进行尺寸调整和灰度归一化。将训练样本尺寸调整为人脸样本  $20 \times 20$ ，人眼样本  $24 \times 18$ 。尺寸的统一能够降低特征提取的复杂度从而节省时间，灰度归一化能够减小一些光照等因素造成的影响。

### 3.4.3 训练分类器

为获得样本分类器，首先要训练样本，然后再进行检测试验。训练分类器的大致流程是：输入正负样本集，在利用积分图的快速运算在矩形特征模板下得到样本的 Haar-Like 特征集。然后输入特征集，采用弱学习算法对每个特征确定对应弱分类器的阈值得到弱分类器集。对于这些弱分类器，通过 AdaBoost 算法选出错误率最低的作为最优弱分类器，进行多轮迭代后得到多个弱分类器。根据这些若分类器的分类能力的强弱给予不同权重，然后组合成强分类器。再把多个强分类器串联起来构成级联分类器。

首先在 DOS 命令下生成正负样本描述文件，样本描述文件包括图片路径(包括绝对路径或相对路径)，样本数目以及各样本在图片中的起始位置和宽与高大小。然后使用 OpenCV 自带的 CreateSamples 程序将准备好的正样本转换为 vec 文件，运行 CreateSamples 程序创建训练样本。然后代码实现训练分类器。其训练分类器需定义参数如下：

```
weakClassifier temp;//弱分类器
int g=1; //样本识别状态
float totalWeights=0.0,totalPos=0.0,totalNeg=0.0,bPos=0,bNeg=0;// 正负样本权重和
float e,thr,besterr=1.0;//训练单个分类器的错误率，阈值，最小错误率
float FThr[FCOUNT];//特征阈值
float minErr=1.0;//所有特征的最小错误率
float beta;//更新权值所需系数
```

本文进行样本训练，最后得到人脸强分类器有 15 级，产生了 928 个特征，人眼分类器 12 级，产生了 734 个特征。人脸分类器层数比人眼分类器层数略高，因为人脸分类器分类层数高能使漏检率变小，从而提高人脸的检测率。而人眼检测都是在人脸定位的基础上进行的，所以人眼的误识率比人脸要低，但同时检测率也很高。

### 3.4.4 实验结果和分析

本文程序是在 VS2008 环境下结合 OpenCV 库进行编程实现的，并分别对含

有人脸的图片样本集和外接 USB 摄像头实时拍摄的人脸视频集进行实验。

检测步骤需要用到 performance.exe, 该程序源码由 OpenCV 自带, 可执行程序在 OpenCV 安装目录的 bin 目录下, 利用 haarconv 的程序, 将生成的分类器转换为.xml 文件, 便于后续使用。随后使用 OpenCV 的 cvHaarDetectObjects 函数进行测试。部分测试语句如下:

```
CvSeq* faces = cvHaarDetectObjects(gray, cascade, storage,
                                     1.2, 2, CV_HAAR_DO_CANNY_PRUNING, cvSize(120, 100)
);
//人脸检测
.....
CvSeq* eyes = cvHaarDetectObjects( faceimg, cascade_eye, storage_eye,
                                   1.1, 2, CV_HAAR_DO_CANNY_PRUNING, cvSize(20,
15) );
//人眼检测
.....
```

对部分 BioID 数据库分别用传统的 AdaBoost 算法直接进行人眼检测即直接利用人眼分类器进行检测, 和改进的 AdaBoost 算法利用构造人脸-人眼分类器进行人眼检测的实验结果对比如表 3.2 所示。

表 3.2 方法对比检测结果

Table 3.2 Detection result of different methods

方法	检测率(%)	平均检测时间(帧/秒)
人眼分类器	89.73	37.86
人脸-人眼分类器	95.12	12.93

实验证明, 改进的 AdaBoost 算法较于传统的算法提高了检测率, 而且明显的缩短了检测时间, 提高了算法检测率, 达到了快速检测人眼的目的。

对部分图片样本集进行人眼检测的检测结果如图 3.6 所示。




图 3.6 部分图片样本集检测结果图

Fig.3.6 Part of detection results for pictures

对部分图片样本集进行人眼检测的实验结果如表 3.3 所示。

表 3.3 图片样本集的检测结果

Table 3.3 Detection result of pictures

样本集	图像数	检测率(%)	平均检测时间(帧/秒)
部分 BioID 库	821	95.12	12.93
自制样本集	600	97.48	31.25

实验表明，在两个样本集中都有较高的检测率，主要是因为所用的样本集都是针对算法训练使用的图片集，多是简单背景的正面人脸图像，所以检测率高。而自制样本集的检测率还要高于 BioID 数据库的检测率是由于自制样本图片分辨率较高、人脸偏转幅度小，而 BioID 数据库图像的分辨率低外加其它光线等因素的影响。同时，两种样本集都有较快的检测速度，能满足实时性的需求，可以快速检测人脸。

由于疲劳检测系统的最终目的是能够实时监测，要能够实时处理视频图像，所以接下来通过对摄像头采集的视频来进行实验。视频采集是用外接 USB 摄像头进行录制，获取图像分辨率为  $640 \times 480$ 。分别对室内多种干扰条件如光线强弱、物体遮挡、头部偏转以及佩戴眼镜等情况进行了多次实验，还在驾驶室内拍摄视频进行了检测。

#### (1) 光线条件

为了测试在不同光线条件对检测效果的影响，对光线过弱、光线正常和光线过强三组不同光线条件下的视频进行检测。检测结果如表 3.4 所示。

表 3.4 不同光线条件下的检测结果

Table 3.4 Detection result of different light

光线条件	过弱	正常	过强
检测率(%)	70.4	98.2	56.5

由表 3.4 可知，正常光线条件下，算法有较高的准确率。当光线过强或过弱时，检测的准确率明显降低。在夜晚行车时，光线很弱，检测效果不佳。在今后的研究中可以考虑使用红外设备来进行视频的拍摄。

#### (2) 物体遮挡

在驾驶过程中可能会出现打哈欠时用手捂一下嘴或者在其他情况下肢体遮挡住了面部以及驾驶员佩戴透明眼镜或者有色眼镜等都会对人眼的检测造成一定影

响。经过实验发现当面部有小部分被遮挡但没有遮挡到眼睛时，对检测结果影响很小，检测率较高。当驾驶员佩戴眼镜时，对检测结果影响很大。如果佩戴有色眼镜，那么有色眼镜会把眼睛特征完全遮挡，导致检测不到人眼。佩戴透明眼镜时，常会出现反光的现象，造成眼部区域特征变得模糊，从而导致检测不到人眼或者出现误判的情况，使得检测率较低。

### (3) 头部偏转

在驾驶过程中，驾驶员不会长时间保持同一个姿势，肯定会出现头部偏转现象。为了测试头部偏转对检测结果的影响，选取偏转角度为  $30^\circ$ 、 $15^\circ$  和  $0^\circ$  三种情况下的视频图像各 30 帧，其检测结果如表 3.5 所示。

表 3.5 不同偏转角度下的检测结果

Table 3.4 Detection result of different deflection angle

偏转角度( $^\circ$ )	30	15	0
检测率(%)	46.7	83.3	93.3

由实验结果可知，不同的头部偏转角度对检测效果有不同的影响。当偏转角度较小时，对检测率影响不大，检测的准确率高。当偏转角度较大时，会很难提取人眼特征，从而导致无法检测，使检测率降低。主要是因为 Adaboost 算法中的训练样主要以正面图像为主，对侧面图像的检测效果不佳。所以只有头部偏转角度在(0,30)范围内，才会有较好的检测效果。

其部分检测结果如图 3.7。




图 3.7 多种情况检测结果

Fig.3.7 Some detection results

实验表明，光线的强弱、头部的偏转角度、物体遮挡等都会对检测产生一定



的影响。但是多数情况下，小幅度的变化对算法的影响不大，算法仍然能够满足实时性检测的要求。经大量实验验证，基于改进的 AdaBoost 算法的人脸-人眼分类器在人眼检测实验时都取得了较好的效果，具有检测率高、检测速度较快的优点。

### 3.5 本章小结

本章首先分析了 AdaBoost 算法出现的退化现象，并针对发现的问题进行算法的改进。然后描述了构造人脸-人眼分类器进行人脸检测的过程。最后详细介绍了基于 AdaBoost 算法的人眼检测的实验流程，从训练样本到训练分类器，最后给出人眼检测的实验结果及实验分析。验证了算法能满足疲劳检测实时性的要求，同时也发现了算法的不足，为今后的改进提供了方向。

## 第 4 章 人眼状态识别及疲劳状态检测

### 4.1 人眼状态识别方法概述

驾驶员的疲劳程度往往可以通过很多特征来反映，而利用眼部状态特征来判断驾驶员疲劳状态因为其有很高的准确率被广泛采用。上文通过使用改进的 AdaBoost 算法对图像进行了人眼检测得到了人眼区域图像，下一步就是进行人眼状态的识别。人眼状态的准确判断会直接影响疲劳检测的结果，所以人眼状态的识别是疲劳检测的关键步骤。对于眼睛状态的判断，即眼睛的睁闭情况，考虑到眼睛包括瞳孔、眼角、虹膜、瞳孔等丰富的特征特点，目前常用的人眼状态检测的方法主要有模板匹配法、Hough 变换检测虹膜法、眼睑曲率法、区域搜索法和投影法<sup>[29]</sup>等。

#### (1)模板匹配法

模板匹配的方法是通过已有的眼睛模板在待检测的人眼图像上进行平移，找到相似区域并比较相似程度，再与阈值进行比较得出结果<sup>[30]</sup>。如果检测的人眼图像和睁眼模板的相似度高就认为眼睛处于睁开状态。如果检测的人眼图像和闭眼模板的相似度高就认为眼睛处于闭合状态。模板匹配方法需要通过大量训练来确定眼睛状态模板，在进行匹配时系统会自动调出训练好的眼睛状态模板中的人眼。但是由于不同的人眼睛有所差异，就可能会出现一些人的睁眼状态和别人的闭眼状态很相似，直观上都无法区分的情况。还会出现与睁眼模板和闭眼模板分别匹配的相似度却相差较小的情况，会出现误检现象。由于匹配过程还会受到光照、表情等因素影响，从而会导致匹配的准确度降低。同时，算法的计算量大，比较耗时，其识别精度越大，算法耗时越长。

#### (2)Hough 变换检测虹膜

利用 Hough 变换进行人眼状态的判断主要运用了 Hough 查找圆的检测方法。其基本原理是，如果眼睛是睁开状态，那么虹膜是可见的，就能够在人眼区域中找到虹膜，也就是能检测到圆。如果眼睛是闭合状态，虹膜被眼睑遮挡住，那么在人眼区域就找不到虹膜，检测不到圆或者只能检测到一部分圆。Hough 变换检

测方法,主要适用于检测睁眼状态的情况,而且他要求比较完整的虹膜边缘信息,需要较高的图像分辨率。如果图像分辨率较低,人眼区域不清晰,就很难获取清晰且完整的虹膜轮廓,很难识别人眼状态。同时, Hough 变换要在高维参数空间来检索,并且算法运算量大实时性较差,对于实时性要求比较强的疲劳检测该方法不太适用。

### (3)眼睑曲率法

眼睑曲率法即通过公式计算得出眼睑部位的曲线的曲率,首先使用边缘检测方法得到人眼边缘的图像,随后只将图像的最上方边缘进行保留,并将其定义为上眼睑,再将上眼睑图像拟合成最相似的曲线,最后计算该曲线的平均曲率。其公式如下:

$$\rho = \frac{\Delta\theta}{\Delta l} \quad (4-1)$$

其中,  $\Delta\theta$  是眼睑曲线切线的变化角度,  $\Delta l$  是弧长。眼睑曲率的近似计算公式如下:

$$\rho = \frac{h}{w} \quad (4-2)$$

其中,  $w$  表示左右眼角之间的水平距离,  $h$  表示左右眼角的中点到  $w$  的垂直距离。若  $\rho > 0$ , 则表示眼睛处于睁开状态, 若  $\rho < 0$ , 则表示眼睛处于闭合状态。眼睑曲率法对眼角的定位要求很高, 而且曲线拟合常会出现误差<sup>[31]</sup>, 从而会降低检测的准确性。

### (4)区域搜索法

区域搜索法定位人眼是通过利用人脸图像中眼睛区域的灰度特征信息和图像二值化来实现的。山世光等人采用了这种方法, 首先扩充已经在人脸检测中检测出来的人脸区域, 使其全部的头面部区域(全部的头面部区域包括绝大部分或全部的头面部以及整个面部)都包含在内。在选择合适的阈值对二值化该图像区域, 在二值图像中用区域标记法标记不同的黑色连通区, 再通过不同大小的图像来设置面积阈值, 用面积阈值过滤掉由噪声形成的独立的连通区, 就定义头发区域为位于全部头面部区域最上方的最大连通区。将头发区域锁定后, 继续寻找剩下的连通区域, 如果发现一些连通区符合某些先验知识的, 那么该连通区即为眼睛区域。

Zhang L.M.等进行了图像二值化处理, 所应用的方法为直方图阈值化方法,

再根据所得二值化图像中出现的深色区域的相对位置、形状和大小等几何特征来定位瞳孔的准确位置，最后应用前文所应用的边缘追踪法分别定位到上眼眶、眼角和下眼眶<sup>[32]</sup>。这种方法的关键是确定阈值和筛选连通区域，其运算量较小，即便是人眼处于闭合状态时也会有黑色的连通片，这种情况下只要对连通片约束阈值范围再结合人眼位置也可以准确的找到人眼。

#### (5)投影法

目前我们经常用到的投影函数包括方差投影函数(varianee projection function, 简称 VPF)、积分投影函数(iniegral projection function, 简称 IPF)和混合投影函数(hybrid projection function, 简称 HPF)。其中，基于灰度的积分投影法是一种非常有效的识别人眼的方法。基本原理是根据积分投影在眼睛睁开和闭合时形成的投影曲线的特征对人眼状态进行判别。当将眼部闭合时，虹膜会被上下眼睑全部遮住，我们会在对闭眼之后产生的图形采用水平积分投影的方法得到的投影曲线中发现单峰，且此单峰宽度较窄，因为眼睛闭合时只有上下眼睑交界处的灰度值比较大。当眼睛睁开时，对人眼图像进行水平积分投影，得到的投影曲线的波峰宽度的变化是取决于眼睛的睁开程度，上下眼睑的距离就可以表示眼睛睁开的程度，也对应着灰度图像中虹膜的面积。利用积分投影法就可以通过这些特性来判断眼睛的睁闭状态，同时眼睛的闭合程度也可以通过分析波峰的宽度来得出。本文采用投影法中的积分投影法来进行人眼状态的识别。

## 4.2 基于投影法的人眼状态识别

投影法能直观的并且有效的将人眼的信息全部提取出来，而且还能够利用二值化<sup>[33]</sup>的图像的投影曲线特征来定义眼睛在闭合时的各种程度，二值化法具有较高的实时性和准确性。本文采取投影法来对人眼状态进行识别。由于正常情况下，人的两只眼睛在轮廓大小、长宽比例以及色彩信息等参数方面基本相同，而且两只眼睛的睁闭状态、眨眼动作等特征也几乎一致，所以本文使用提取一只眼睛的参数信息来表示两只眼睛的共同状态的方式。

### 4.2.1 图像的二值化

图像的二值化的过程是指将所选择的阈值图像上的灰度值调至为0或者255，从而使图像完全变成黑白。图像的二值化能将生成的图像变单一，降低数据的总

量，能显示出所需要的轮廓，有利于对图像的进一步处理。显然，人眼区域的灰度值要比其他面部区域的灰度值低，通过二值化处理就能够把人眼特征在图像中凸显出来，有利于下一步的人眼状态判断。在图像二值化过程中，最重要的是阈值的选取，若阈值选取不合适就会造成二值化图像不能很好地显示出感兴趣的目标轮廓信息。由于人眼区域包含肤色、眼睛、眼睑、虹膜、瞳孔及眼白等各种信息，为了满足识别的精细度和准确性，本文选择 Otsu 最大类间方差法二值化处理人眼区域，这种方式能够将目标和背景的自适应阈值差别变大从而将眼部信息与背景信息完全分离开。

目前，确定阈值有很多方法，常用的图像二值化方法<sup>[34]</sup>有：Otsu 最大类间方差法、Dither 矩阵法、自适应阈值、直方图阈值分割法等。对于以上方法，对所得数据进行图像二值化处理的最重要步骤是选取确定阈值，而选择阈值的要进行多次的实验并要对所得的各类数据结果进行整合之后才能得到最终的阈值，从而达到分割出目标区域和背景的目的。其中 Otsu 最大类间方差算法是比较常用而且效果也较好的方法，可以说它是自适应计算单阈值的一种简单高效的方法。

最大类间方差法<sup>[35]</sup>是日本学者大津(Nobuyuki Otsu)在 1979 年提出的，它是一种自适应的阈值确定的方法，又称为大津法,简称 Otsu。它的基本思想是按照图像的灰度特性(像素点灰度值)分为两类，最理想的阈值就是取得两类像素点方差最大值时的极值点。Otsu 二值化算法将图像分成背景和背景两类，分类依据是通过改变图像的像素点灰度值。如果得出的背景与目标所形成的类间方差越大，那么就说明构成图像的两类的差别比较大，当部分目标与背景被错分时，背景与目标的差别就会变小。如果所得的类间方差达到最大值，那么就说明错分概率达到最小，也就得到了最终要得到的二值化阈值。

Otsu 二值化算法有以下优点：

- (1)算法简单，易于实现；
- (2)基于的整体特性而非局部特性；
- (3)将其推广为多阈值分割方法相对更容易一些；
- (4)实用性很强。

假设图像灰度范围 $D \in (0, K)$ ，其中  $K$  是最大灰度值，灰度值 $t \in [0, K]$ ，把图像中所有像素点分为 A 和 B 两类，A 类像素点的灰度范围 $D_A \in (0, t)$ ，B 类像素

点的灰度范围  $D_B \in (t+1, K)$ ，各灰度值在图像中出现的概率为  $P_i$ 。则

$$P_i = \frac{n_i}{N} \quad (4-3)$$

其中， $N$  是像素点总数， $n_i$  是灰度值为  $i$  的像素点的个数。

A 类像素点出现的概率：

$$\eta_A = \sum_0^t P_i \quad (4-4)$$

B 类像素点出现的概率：

$$\eta_B = \sum_{t+1}^K P_i = 1 - \eta_A \quad (4-5)$$

A 类像素点的均值：

$$\lambda_A = \sum_0^t i P_i \quad (4-6)$$

B 类像素点的均值：

$$\lambda_B = \sum_{t+1}^K i P_i \quad (4-7)$$

A 和 B 类间的方差：

$$\sigma(t)^2 = \eta_A \eta_B (\lambda_A - \lambda_B)^2 \quad (4-8)$$

在灰度范围  $D \in (0, K)$  内，当  $\sigma(t)^2$  取得最大值时， $t$  的值就是最理想阈值  $T$ 。人眼图像二值化效果如图 4.1 所示。



图 4.1 人眼二值化效果图  
Fig.4.1 The human eye binary

#### 4.2.2 数学形态学处理

虽然通过 Otsu 最大类间方差法能够将眼睛信息从人眼区域图像背景中很好的分离出来，但是会发现图像中有很多干扰，诸多干扰是皮肤纹理、睫毛或者虹膜反光等原因多产生的，它们会产生小的噪点或者线性区域，从而间接影响提取眼睛的有效信息。所以本文利用数学形态学处理方法继续对人眼的二值化图像处理以达到去除噪点和避免干扰的效果。

数学形态学是一种非线性理论，现在被广泛应用在图像处理领域，它本身就拥有独立完整的体系结构，从概念、方法到算法都有完整的体系。它分析图像是通过形状结构的方式来表现，这种方式非常直观和新颖。近年来，数学形态学处

理方法在图像处理领域广泛应用，有着良好的发展前景。数学形态学方法的主要运算包括腐蚀(Erosion)，膨胀(Dilation)，开运算(Opening)和闭运算(Closing)。

腐蚀是使用某种基元或者结构元素来搜索一个图像，在图像中找到可以放下该基元的区域。具体定义如下：

$$A \otimes B = \{x | (B)_x \subseteq A\} \quad (4-9)$$

上式表示用  $B$  来腐蚀  $A$  的结果是：当  $B$  完全包含在  $A$  中时， $B$  的原点位置的集合。当使一个  $3 \times 3$  的结构元素被腐蚀，则该物体边界会相应的减少一个元素。腐蚀操作是一个消除物体边界点的过程，操作后会使得物体比原来的面积小，还可以消除边界上多余的小区域，把边界向内部收缩。因此腐蚀可以用来对二值化图像中面积很小的干扰区域和离散的点来进行消除。如果想要消除两个物体之间的细小的连通，那么可以通过选择足够大的结构元素来进行腐蚀操作。

膨胀是腐蚀的对偶运算，其具体定义如下：

$$A \oplus B = \{x | [( \hat{B} )_x \cap A] \neq \emptyset\} \quad (4-10)$$

$$\hat{B} = \{x | x = -b, b \in B\} \quad (4-11)$$

其中， $\hat{B}$  是集合  $B$  关于原点的映射。上式说明  $B$  来膨胀  $A$  的结果是，当  $\hat{B}$  的位移和集合  $A$  最少有一个交集时， $B$  的原点位置的集合。

膨胀操作的结果是把周围的背景点合并到物体中，使物体边界扩张。膨胀操作可以把两个距离较近的物体连接成一个，还可以用来填补物体中的空洞。

腐蚀膨胀过程如图 4.2 所示。




图 4.2 腐蚀和膨胀过程示意图

Fig.4.2 The process of erosion&dilation

开运算：是先腐蚀后膨胀的过程。其定义如下：

$$A \circ B = (A \otimes B) \oplus B \quad (4-12)$$

开运算操作过程中，先腐蚀可以去除边界区域像素点，删除图像边缘细微的

点或线，然后再进行膨胀操作，图像边界扩张可以恢复到原始大小，但是腐蚀操作中去除的边界点被永久去除不会再恢复。开运算操作可以平滑图像的边界区域，所以经常用开运算处理在不改变原图像面积的情况下去除小范围的像素点、断开狭窄的连通区域和细小毛刺等问题。

闭运算：是先膨胀后腐蚀的过程。其定义如下：

$$A \bullet B = (A \oplus B) \otimes B \quad (4-13)$$

闭运算操作与开运算正相反，它是先膨胀扩张物体边界，对图像区域的细小空洞或线条进行填补，然后再进行腐蚀操作，图像的边界区域收缩回原始大小，且在膨胀过程中会永久去除空洞和线条不再复原。闭运算操作可以在基本不改变原图像区域大小的前提下，对图像区域内的小空洞或线条进行填充，把相邻区域连通起来，还可以平滑图像的边界区域。

虽然开运算和闭运算操作都可以平滑图像的边缘轮廓，但是开运算能够去除边缘的细小毛刺凸起，断开狭窄的连通区域，去除噪点和细线的干扰。所以，对二值化后的人眼图像做开运算操作处理。开运算处理之后的人眼图像如图 4.3 所示：




图 4.3 开运算操作效果图

Fig.4.3 Effect of open operation

经过开运算操作处理后的人眼图像边界区域更加平滑，处理前图像中的毛刺凸起、皮肤纹理等噪点基本被消除，而且保留了眼睑和虹膜等这些重要的信息。所以，数学形态学处理图像有利于对人眼状态的分析。

### 4.2.3 人眼状态的判断

经过数学形态学图像处理后可以提出人眼区域的轮廓信息，为接下来的人眼状态的识别做好了准备。人眼状态识别的目的是判定驾驶员眼睛的睁闭状态，其判定依据是通过对眼睛信息的参数分析。为了进一步判定驾驶员的疲劳状态，可以利用人眼状态信息再结合一定的疲劳检测方法进行实验。本文采用积分投影法来提取人眼的有效信息，然后通过所得的相关信息来判断人眼的闭合状态。



一般的投影法是将人眼区域图像投影到垂直方向，然后再根据投影曲线来分析，通过曲线的波峰宽度来确定在某一时刻下人眼的高度，再经过统计分析确定一个人眼高度的阈值。如果人眼的高度大于这个阈值，就说明人眼是睁开状态，人眼高度小于这个阈值，就说明人眼是闭合状态。因为每个人的眼睛大小有很大不同，所以不同的驾驶员在睁眼状态下眼睛的高度也有所差异，这样如果直接通过眼睛高度像素值来识别眼睛状态就会有一定误差，同时该方法也会受到视频图像分辨率等因素的干扰，所以有一定的局限性。利用积分投影法不但可以确定人眼的高度的像素值，而且还可以确定人眼的宽度的像素值。研究发现，虽然每个人的眼高度差异大，但是人眼高度和宽度的比例在眼睛睁开或者闭合时的差异却不大，能在较小的范围中上下浮动，并且不会受到视频图像像素问题的干扰。所以本文使用通过积分投影计算人眼的高宽比例的方法来判断人眼的闭合程度。

对二值化和数学形态学处理后的人眼区域图像，进行积分投影，在投影曲线上得出人眼高度和宽度像素值，再求出高宽比例就可以判断人眼的闭合状态。该方法的基本原理是使用遍历法来遍历人眼图像，从左到右遍历图像中所有的像素点，当搜索到第一个像素值为 255 的像素点即黑色像素点时，记为人眼的左边缘点，同样再进行从右到左、从上到下和从下到上方向的遍历，可以找到人眼的右边缘点、上边缘点和下边缘点，这样就可以计算出人眼的竖直高度和水平宽度的像素值。记人眼的竖直高度为 $e_h$ ，水平宽度为 $e_w$ ，高宽比例为

$$\lambda = \frac{e_h}{e_w} \quad (4-14)$$

崔坚通过实验分析得出， $\lambda$ 最大值约为 0.43，最小值约为 0.16，当 $\lambda \leq 0.23$ 时人眼状态处于闭合程度在 80%以上的状态<sup>[36]</sup>。

## 4.3 基于 PERCLOS 方法的疲劳状态检测

### 4.3.1 PERCLOS 方法检测原理

PERCLOS<sup>[37]</sup> (Percentage of Eyelid Closure over the Pupil over Time, 简称 PERCLOS) 即将人眼完全闭合的时间占规定时间的比例。到目前为止，PERCLOS 检测方法被认为是对驾驶员进行驾驶疲劳评定检测的最有效的方法，是公认的疲劳状态评价的标准。1994 年 Walt Wierwille<sup>[38]</sup>最早提出 PERCLOS 检测方法，它的根本理论是研究眼睛、光学变量与疲劳的之间的关系，研究人眼的睁闭状态和

疲劳程度之间的关系。最后得出了 PERCLOS 方法，即通过计算人眼闭合时间比例来快速评价驾驶员疲劳状态。Walt Wierwille 以及其他学者在驾驶模拟器上所做实验得出的结果如图 4.4 所示。




图 4.4 驾驶模拟器上的测试结果

Fig.4.4 Driving simulator test results

图 4.4 中横坐标是事故发生的时间序列，整个序列的零点是事故发生的时刻，正数表示事故发生后，负数表示事故发生前，绝对值表示该时刻距离事故发生时刻的时间。图中，由发生意外事故的时间与人眼闭合的时间关系可以得到，在事故发生前人眼闭合的时间比事故发生后人眼闭合的时间要长，由此可知疲劳程度是驾驶员眼睛闭合时间的长短的关键因素。在某种程度上认为，驾驶员眼睛闭合的时间越长他的疲劳程度就越严重。如果驾驶员的眼睛长时间处于闭合状态，那么就有可能导致交通事故的发生。因此若要测定驾驶员的疲劳程度，可以通过及时的测量眼睛闭合时间的长短进行检测判断。

1999 年 4 月，美国联邦公路管理局 FHWA(Federal Highway Administration) 召集多名研究人员来对 PERCLOS 原理进行了评估，并且和其他的疲劳检测方法做了对比。研究结果显示，目前为止 PERCLOS 方法判断疲劳的性能最好，是作为车载的、实时的、非接触的驾驶员疲劳检测的首选方法<sup>[39,40]</sup>。

PERCLOS 方法的常用标准有三种：P70、P80 和 EM。其标准定义如下：

**P70 标准：**指当眼睑遮住瞳孔的面积超过 70% 时认为眼睛是闭合状态，统计眼睛闭合时间所占某一时间段的比例。

**P80 标准：**指当眼睑遮住瞳孔的面积超过 80% 时认为眼睛是闭合状态，统计眼睛闭合时间所占某一时间段的比例。

**EM 标准：**指当眼睑遮住瞳孔的面积超过一半时时认为眼睛闭合状态，统计眼睛闭合时间所占某一时间段的比例。

研究表明 PERCLOS 的 P80 标准与驾驶疲劳程度的相关性最好，而且具有良好的线性关系<sup>[41]</sup>。其曲线如图 4.5 所示。




图 4.5 P80 与疲劳程度的线性关系

Fig.4.5 The linear relationship of P80 and fatigue degree




图 4.6 PERCLOS 测量原理

Fig.4.6 PERCLOS measuring principle

以 P80 为例，PERCLOS 的测量原理如图 4.6 所示。它实质就是眼睛的一次完整眨眼过程，表示了眼睛从完全睁开到完全闭合再完全睁开的整个过程。其中，时间在横坐标轴上，眼睛闭合的程度在纵坐标轴上表示。 $t_1$ 表示眼睛从完全睁开到闭合 20%所用的时间， $t_2$ 表示眼睛从完全睁开到闭合 80%所用的时间， $t_3$ 表示眼睛从完全睁开到下一次闭合 80%所用的时间， $t_4$ 表示眼睛从完全睁开到下一次闭合 20%所用的时间。分别测量出 $t_1$ 、 $t_2$ 、 $t_3$ 、 $t_4$ ，就可以计算出 PERCLOS 的值 $f$ ，其计算公式如下：

$$f = \frac{t_3 - t_2}{t_4 - t_1} \times 100\% \quad (4-15)$$

设定一个阈值，当 $f$ 大于该阈值时，就判定驾驶员处于疲劳状态。

### 4.3.2 基于动态 PERCLOS 辅助眨眼频率的疲劳状态判断

基于 PERCLOS 方法进行驾驶员的疲劳状态检测，先通过摄像头捕获一帧驾驶员的脸部图像，之后确定人脸区域，再对人眼进行精确定位并获取眼睛特征信息，根据眼睛高宽比判断出人眼状态，最后测量 PERCLOS 值来判断驾驶员是否疲劳驾驶。PERCLOS-P80 标准下，记在某一时间段内采集的视频图像中，眼睛闭合 80% 状态的帧数为  $n$ ，总帧数为  $N$ ，用图像帧数百分百替换时间百分百来表示 PERCLOS 的值  $f$ ，则

$$f = \frac{n}{N} \times 100\% \quad (4-16)$$

当驾驶员处于疲劳状态时，可能出现眨眼时间变长、眼睛长时间闭合的现象，也可能是眼睛睁开程度小，处于半睁开状态或者接近完全闭合的状态。通常，人的眨眼发生过程很迅速，而眼睛在眨眼的过程中处于闭合状态的时间更短暂。所以在一段时间内，如果眼睛闭合时间过长，就可能处于疲劳状态。眼睛闭合时间过长的同时会导致眨眼频率降低，因此眨眼频率过低时很有可能处于疲劳状态。

眨眼频率是指单位时间内完成完整的眨眼过程的次数。一般情况下，人眼每分钟眨眼次数为 10~15 次。如果眨眼频率过低，可能的原因有两个，一是驾驶员处于疲劳状态，出现长时间闭眼情况，二是驾驶员虽然眼睛是睁开状态，但是目光呆滞，处于走神状态。第一种情况可以通过 PERCLOS 方法来计算单位时间内检测的闭眼帧数；第二种情况虽然驾驶员走神，但是眼睛仍处于睁开状态，PERCLOS 值比较低，PERCLOS 方法就判断不出驾驶员是否状态异常，这种情况就可以用眨眼频率来判断了。如果眨眼频率过低，就说明驾驶员眼睛状态异常，也需要给予预警。

李都厚等<sup>[42]</sup>还提出了由于人自身的生理节律，在一天当中会在 2:00-6:00、11:00-13:00 和 15:00-16:00 三个时间段最易出现疲劳状态。所以本文考虑把易出现疲劳时间段和其他的一般时间段分开使用不同的 PERCLOS 值来判断驾驶员的疲劳状态。采用随时间变化的动态 PERCLOS 值，在易疲劳时间段使用 P70 标准，在一般时间段使用 P80 标准同时辅助眨眼频率来判断疲劳状态以达到提高算法检测的稳定性的目的。利用 PERCLOS 值进行疲劳判断时，P80 标准下阈值  $f$  取 0.15，P70 标准下阈值取 0.14，在一分钟内如果眨眼次数小于等于 10 则认为是疲劳状态。

改进的 PERCLOS 方法的判断疲劳状态的过程：先通过摄像头捕获驾驶员图像，统计每分钟检测到的闭眼图像的帧数和总帧数，计算眨眼的次数，根据视频时间是否是易疲劳时间段进行不同的判断。若是易疲劳时间段，则根据 P70 标准设定的阈值与计算的 PERCLOS 值相比较，若大于该阈值就判定为疲劳状态发出预警，若小于该阈值则进一步去比较眨眼频率是否小于等于 10，小于等于 10 说明是疲劳状态，反正是正常状态。若是一般时间段，根据 P80 标准设定的阈值与计算的 PERCLOS 值相比较，后续步骤和易疲劳时间段相同。疲劳判定流程如图 4.7 所示。

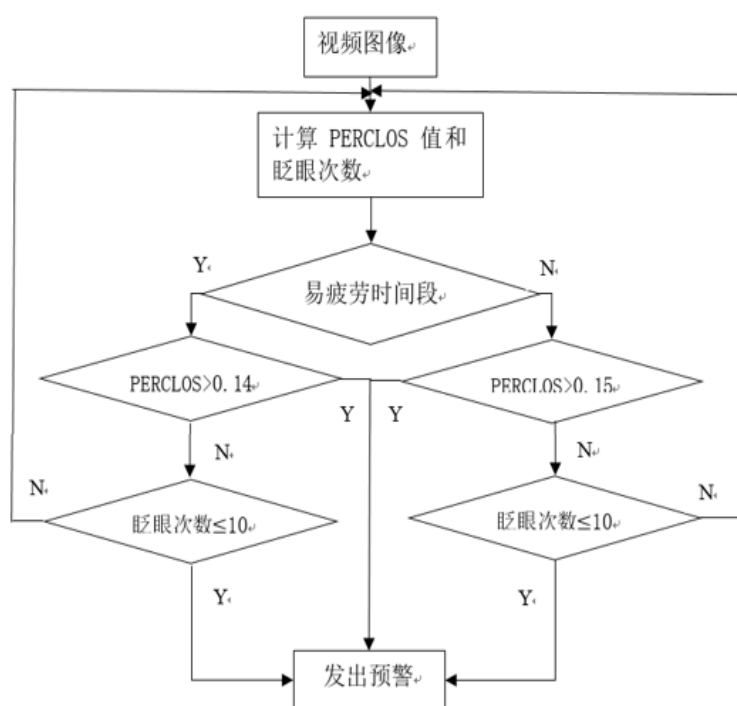


图 4.7 疲劳判定流程图

Fig.4.7 Flowchart of fatigue determine

## 4.4 实验结果及分析

### 4.4.1 实验平台

本文驾驶员疲劳状态检测的实现所涉及的算法均采用 C、C++ 的开发语言,在 Visual Studio 2008 环境下,借助开源计算机图像处理库 OpenCV 来进行编程实现。本文的驾驶员疲劳状态检测系统硬件部分包括 PC 机和摄像头两部分。其参数如下:

(1)采用的 PC 机基本配置参数:

处理器: Intel(R)Core(TM)i3 CPU,2.53GHZ

内存: 2GB

系统类型: 32 位操作系统

操作系统: Windows 7

(2)采用的摄像头参数:

品牌型号: 魔景 T21 摄像头

传感器: CMOS 彩色传感器

分辨率: 640×480

图像速率: 15-30 帧/秒

接口类型: USB2.0

VFW 接口: 支持动态视频图像和静态图像捕获

兼容免驱动: 支持 Window XP/Win7/Win8

#### 4.4.2 实验结果

疲劳状态的检测算法实现的基础是人眼检测, 人眼检测的具体过程和实验结果已在上一章做了详细说明。检测出人眼区域后判断人眼状态, 最后完成疲劳状态检测。疲劳状态检测系统界面包含当前帧数、PERCLOS 值以及显示是否疲劳。以室内环境和车内驾驶环境为背景进行实验。

室内环境下的部分疲劳检测系统效果图如图 4.8、4.9 所示。



图 4.8 人眼检测效果图

Fig. 4.8 Eye detection results



图 4.9 疲劳状态检测效果图

Fig. 4.9 Fatigue state detection results

车内驾驶环境下的部分疲劳检测系统效果图如图 4.10、4.11 所示。

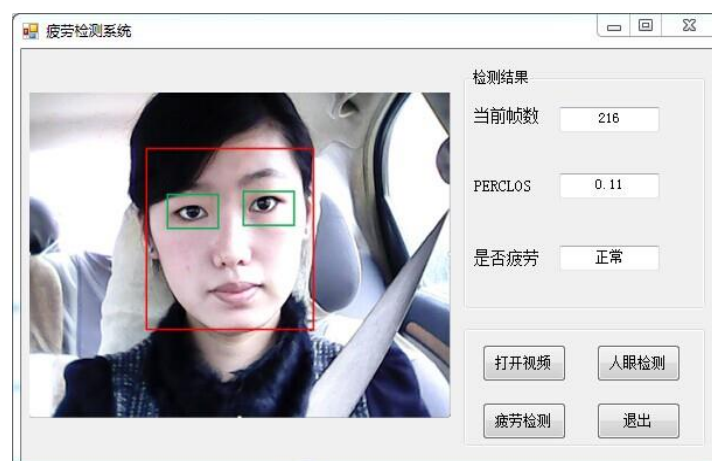


图 4.10 疲劳状态检测效果图 1

Fig. 4.10 Fatigue state detection results 1



图 4.11 疲劳检测效果图 2

Fig. 4.11 Fatigue state detection results 2

为验证本文疲劳状态检测算法准确性,选取多名测试人进行试验,分别在正常时间段和易疲劳时间段采集测试视频各 30 秒,共采集正常状态和疲劳状态视频样

本各 20 组。部分实验检测结果如表 4.1、4.2 所示。

表 4.1 部分实验检测结果

Table4.1 Part of the experimental results

	视频 1	视频 2	视频 3	视频 4	视频 5
时间段	正常	正常	易疲劳	易疲劳	正常
样本状态	正常	疲劳	疲劳	疲劳	正常
PERCLOS 值	0.08	0.23	0.33	0.11	0.13
眨眼频率（次/分钟）	15	12	8	9	20

表 4.2 部分实验准确率

Table4.2 Part of the experimental accuracy

	视频 1	视频 2	视频 3	视频 4	视频 5
准确率（%）	90.5	84.6	81.9	82.4	85.2

实验结果证明，对人眼睁闭状态的检测效果明显，有较好的效果。但是经统计发现，实验会出现部分漏检情况，经分析漏检情况主要发生在脸部方向偏移角度较

大的情况。主要是由于侧脸时，对人眼信息的提取和疲劳状态的检测影响很大，极易导致漏检或误检。因此，在视频图像采集时，要尽量从正面采集驾驶员的面部视频，而且头部偏移角度不能过大，尽量保持在 30°以内。视频窗口还要距离驾驶员位置适中，以保证采集到驾驶员完整的脸部图像。在光线弱的时候，人眼检测的准确率不高导致人眼信息特征模糊，也会导致疲劳检测的失败。

## 4.5 本章小结

本章首先介绍了用于人眼状态识别的主要方法，经过分析，选择了基于投影法的人眼状态检测算法，在此之前先对检测出的人眼图像进行二值化处理和数学形态学处理，然后再进行人眼状态的判断。其次，详细介绍了 PERCLOS 方法检测原理，并在针对使用 PERCLOS 方法的疲劳状态检测方法加以改进，采用了基于动态的 PERCLOS 同时辅助眨眼频率的疲劳判定方法，并给出了疲劳判定流程图。最后，对模拟环境下的视频图像进行实验，取得了较好的检测结果，给出了部分实验结果和检测系统效果图。通过分析发现，对于头部有较大角度偏转的图像难以进行人眼检测，给疲劳状态检测带来了很大的影响。这样，也为下一步的



研究工作提供了方向。

## 结 论

本文通过对采集的驾驶员面部图像信息来检测分析驾驶员的疲劳状态。先对图像进行人脸检测,然后在人脸检测的基础上通过改进的 AdaBoost 算法进行人眼检测,通过人眼的定位来提取眼睛特征参数并对眼睛状态进行判定,最后结合 PERCLOS 方法增加辅助条件来检测驾驶员是否处于疲劳状态。

本文主要完成的工作如下:

(1)本文首先利用 Haar-Like 特征和积分图进行计算的快速 AdaBoost 算法进行人脸检测,随后采用改进的 AdaBoost 算法进行人眼检测,针对传统 AdaBoost 算法的退化现象以及困难样本中正负样本没有加以区分的情况,在算法中引入样本状态识别标记并利用新的样本权重更新方法来训练分类器。采用构造人脸-人眼分类器的方法对人眼进行检测,实验证明使用改进的算法能够缓解退化现象并提高了检测率。

(2)人眼检测完成后,进行人眼状态判定时本文采用了基于投影法的人眼状态检测算法,先对检测到的人眼区域图像通过 Ostu 最大类间方差法进行二值化处理,随后进行数学形态学处理,然后通过积分投影法对人眼信息进行提取,求得眼睛的宽高比,最后根据该比值来判断眼睛的睁闭状态,为后续的疲劳状态检测工作提供了参数和依据。

(3)本文采用了一种基于动态的 PERCLOS 辅助眨眼频率的疲劳状态检测方法。采用随时间变化的动态 PERCLOS 值,在易疲劳时间段使用 PERCLOS-P70 标准,在一般时间段使用 PERCLOS-P80 标准,然后再辅助眨眼频率来进行疲劳状态的判断,提高了疲劳检测系统的稳定性。

尽管本文实现了驾驶员的疲劳状态检测,但是本文还存在不足之处,需要进一步的研究和实现:

(1)本文对于头部偏转角度过大的图像,AdaBoost 算法训练的强分类器不能够准确的检测到人眼,从而影响疲劳状态的检测。针对这种情况,可以考虑扩展更适用于检测的矩形特征,或是通过旋转视频图像来解决。对于光线较暗的夜晚,还可以考虑引入红外光源,采集视频时使用红外摄像头来拍摄,并利用红眼<sup>[43,44]</sup>

效应来实现人眼检测。

(2)本文进行疲劳状态检测仅从人眼特征入手，提取眼睛状态信息进行疲劳判定，而没有对其他与疲劳相关的面部器官深入研究，检测结果不够准确。可以采取检测多种疲劳特征融合的方式，对多种疲劳特征进行综合判定，从而提高疲劳检测系统的准确性和可靠性。

疲劳驾驶是引发交通事故最重要的原因之一，能否有效的检测驾驶员的疲劳状态并及时给出预警，对于预防交通事故保障交通安全具有重要的研究价值。由于基于人眼检测的驾驶员疲劳状态检测方法具有非接触而且直观的特点，因此该方法有着广阔的发展空间。本文还有很多地方有待在今后的学习研究中进一步改进。

## 参考文献

- [1] 国家统计局.中国统计年鉴[J].北京:中国统计出版社,2013.
- [2] Chang T H,Hsu C S,Wang C,et al.On board Measurement and Warning Module for Irregular Vehicle Behavior[J].IEEE Trans.Intell.Transp.Syst.,2008,9(3):501-513.
- [3] 孙玮,李晓莹.避免疲劳驾驶的“驾驶员警示系统”.交通世界(运输.车辆),2006(1):57.
- [4] Takahashi I,Yokoyama K. Development of a feedback stimulation for drowsy driver using heartbeat rhythms.Engineering in Medicine and Biology Society. Boston. 2011.4153-4158.
- [5] King L M,Nguyen H T,Lal S K L.Early Driver Fatigue Detection from Electroencephalography Signals using Artificial Neural Networks[J]. Proceedings of the 28th IEEE EMBS Annual International Conference,New York City,USA,2006:2187-2190.
- [6] 焦昆,李增勇,陈铭,王成焘.驾驶精神疲劳的心率变异性和血压变异性综合效应分析[J].生物医学工程杂志,2005,22(2):127-130.
- [7] Weng M C,Chen C T,Kao H C.Remote Surveillance System for Driver Drowsiness in Real-time Using Low-cost Embedded Platform[J].IEEE International Conference on Vehicular Electronics and Safety,ICVES,Columbus,OH,2008:288-292.
- [8] Qin Huabiao.Driver Fatigue Detection Device and Testing Methods Based on the Integration of Diverse Information,Invention Patent Applications Pubilshed Instructions[C].200910038613.3(in Chinese)
- [9] 刘灵,邓小燕,徐颖.汽车驾驶员监测方法与装置的研究现状[J].医疗卫生装备,2006,27(12).
- [10] 郝王蕾.基于人眼特征的驾驶员疲劳检测技术的研究与实现.[D].[硕士学位论文].沈阳:东北大学,2011.

- [11] Kauichi S. Fatigue and Drowsiness Predictor for Pilots and Air Traffic controllers [C].Annual ATCA Conference. 2000: 22-26
- [12] 李峰,曾超,徐向东等.驾驶防瞌睡装置中人眼快速定位方法研究[J],光学仪器,2002,24(4): 122-124.
- [13] 杜勇.基于面部信息的驾驶者疲劳状态分类方法研究[D].[博士学位论文].哈尔滨:哈尔滨工业大学,2012.
- [14] 赵雪竹.基于 AdaBoost 算法的驾驶员疲劳检测[D]. [硕士学位论文].广州:华南理工大学,2010.
- [15] 石坚,吴远鹏,卓斌.汽车驾驶员主动安全性因素的辨识与分析.上海交通大学学报,2000,34(4):441-444.
- [16] 郑培.机动车驾驶员驾驶疲劳测评方法的研究[D]. [硕士学位论文].北京:中国农业大学,2001.
- [17] 王荣本,郭克友,储江伟.一种基于 Gabor 小波的驾驶员眼部状态识别方法的研究.中国图象图形学报.2003.8(9):1043-1047.
- [18] 刘志强.驾驶员疲劳监测方法[J].农业机械学报,2006,37(4): 210-217.
- [19] Hjelmås E,Low B K. Face Detection: a Survey[J], Computer Vision and Image understanding, 2001,83(3): 236-274.
- [20] Yang M H,Kriegman D J, Ahuja N. Detecting Faces in Images: a Survey[J], IEEE Transactions on Pattern Analysis and Machine Intelligence. 2002,24(1): 34-58.
- [21] Paul Viola, Michael Jones. Rapid Object Detection using a Boosted Cascade of Simple Features. Accepted Conference on computer Vision and Pattern Recognition, 2001:2-5.
- [22] 刘江伟.基于人眼检测的驾驶员疲劳状态识别技术[D]. [硕士学位论文].哈尔滨:哈尔滨工业大学,2008.
- [23] 黄福珍,苏剑波.人脸检测[M].上海:上海交通大学出版社,2006:63~64.
- [24] 陈明初.基于人眼状态的驾驶员疲劳检测技术研究.[D]. [硕士学位论文].重庆:重庆大学,2012.
- [25] 张骏. Boosting 方法及其在图像理解中的应用研究.[D]. [硕士学位论文].安

- 徽:合肥工业大学, 2009.
- [26] L.Ke,J.J.Kang, Eye Location Method Based On Haar Features[C], Proceedings of International Congress on Image and Signal Processing, 2010:925-929.
- [27] 梁涛.机动车驾驶员视频图像疲劳检测算法研究 [D]. [硕士学位论文].西安:西安工业大学,2013.
- [28] 孟勇.人眼状态及疲劳检测技术研究 [D]. [硕士学位论文].西安:西安电子科技大学,2012.
- [29] 徐艳,陈孝威.基于差分投影和梯度向量流场的眼睛特征提取[J].计算机工程,2005,31 (4):26-28.
- [30] 关玉萍.基于视频的驾驶员疲劳检测技术的研究[D]. [硕士学位论文].哈尔滨理工大学,2010.
- [31] 曲培树,董文会.基于眼睑曲率及模糊逻辑的人眼状态识别[J].计算机:与科学,2007,29(8):50-53.
- [32] Jie Chen, Xilin Chen. Optimization of a training set for more robust face detection[J]. Pattern Recognition, 2009, 42(11): 2828-2840.
- [33] 孙少林,马志强,汤伟.灰度图像二值化算法研究[J].价值工程,2010(5):142-143.
- [34] 侯科.基于 OpenCV 的疲劳驾驶检测系统的设计与实现 [D]. [硕士学位论文].武汉:华中科技大学,2012.
- [35] 胡卓.基于人眼检测的疲劳驾驶监测技术研究 [D]. [硕士学位论文].北京:北京交通大学,2009.
- [36] 崔坚.基于眼部识别的驾驶员疲劳检测方法研究 [D]. [硕士学位论文].大连:大连海事学,2013.
- [37] 黄翰敏,基于汽车驾驶员疲劳状态检测技术的汽车主动安全系统研究 [D]. [硕士学位论文],重庆:重庆大学,2007.
- [38] 彭明,杨雪峰,应江婷,贾培峰,杨彬彬,疲劳驾驶警示系统在公交车的应用探讨 [J].公路交通科技(应用技术版),2011:291~293.
- [39] LIYING LANG,HAOXIANG QI.The Study of Driver Fatigue Monitor Algorithm Combined PERCLOS and AECS[J].IEEE 2008

- International Conference on Computer Scinece and Software Engineering,2008:349-352.
- [40] BERGASA L.M,NUEVO J,SOTELO M.A,et al.Real-time system for monitoring driver vigilance[J].IEEE Transactions on Intelligent Transportation Systems,2006:63-77.
- [41] 黄翰敏,基于汽车驾驶员疲劳状态检测技术的汽车主动安全系统研究[D].[硕士学位论文],重庆:重庆大学,2007.
- [42] 李都厚,刘群袁伟,刘浩学.疲劳驾驶与交通事故关系[J].交通运输工程学报,2010,10(2):104-108.
- [43] Mormoto C.Flickner M. Real-time multiple face detection using active illumination[J].Proc of IEEE International Conference on Automatic face and Gesture Recognition.2000.
- [44] Haro A. Flickner M.Detection and tracking eyes by using their physiological properties,dynamics and appearance[J].Proc of IEEE Conference on Computer Vision and Pattern Recognition.2000.

## 攻读硕士学位期间发表的论文和取得的科研成果

- [1] Xiaojun He,Jing Liu,Zhendi Yi,Yuanquan Yang,Development of Detection Research on Fatigue Driving.ICCAHE 2014,Hydraulic Engineering and Sustainable City Development III,Vols.641-642,2014:813-817.



## 致 谢

时光飞逝，转眼间两年半的研究生生活即将结束，心中感慨万千。两年半的校园生活给我留下了很多美好的回忆，不仅学到了专业知识，更得到了老师和同学的帮助，这些都是我人生中宝贵的财富。在论文即将完成之际，向所有帮助、支持和关心过我的老师、同学和朋友们致以衷心的感谢。

首先要感谢我的导师和晓军教授，在研究生生涯中给予的关心、指导和帮助。和老师严谨求实的治学态度，渊博的学识，开阔的学科视野，和蔼可亲的待人方式和谦逊的人格在学术研究和生活态度上都对我产生了很大的影响，让我受益匪浅。在学习上，不管和老师多么繁忙，她都会抽出时间督促研究近况并给予我悉心的指导。在论文完成期间，从课题的选定到论文的撰写以及到最终的定稿，每个环节都伴随着老师悉心的指导和帮助。在生活上，和老师和蔼可亲，经常以朋友的身份跟我们谈心，常以自己的亲身经历来教育帮助我们如何处理身边的小事，时刻给予我们热忱的关怀。在今后的工作和生活中谨遵老师的教诲，踏实努力、积极进取、乐观向上的面对每一件事。

感谢乔寅等师兄师姐，谢谢你们在学习和研究中给予我的指点和帮助。感谢同学易贞弟陪伴着我一起互相督促学习、携手进步。同时我们也建立了深厚的友谊，成为了日后互相帮助的良好益友。

感谢所有在我学习生涯中教育我的老师，我的成长离不开你们的帮助。最后，衷心感谢在百忙之中抽出时间审阅本论文和参加答辩的所有专家、老师们，感谢你们提出各种建议和意见，感谢你们的严格把关！再次衷心感谢所有给予我帮助的人！